Livrable L1 – État de l'art

Allocation adaptative des ressources de calcul et de recherche documentaire
pour des systèmes LLM locaux, économes et fiables

Adaptive Compute and Retrieval Allocation for Energy-Efficient and Reliable Local LLM Systems

Alae Lahbichi – Étudiant en 5e année IA/Data

a.lahbichi2004@gmail.com

Dépôt GitHub : AlaeLahbichi/Adaptive-Compute-and-RAG-for-Efficient-Reliable-Local-LLMs

Version de travail v0.1 – 17 octobre 2026

Statut du document. Cette version a été rédigée à partir des métadonnées et des résumés des articles recensés ; les lectures approfondies (passes 2 et 3) restent à faire. Les affirmations sur le contenu des articles doivent être vérifiées dans les textes complets avant toute réutilisation dans un article. Le positionnement proposé (section 10) est une *hypothèse de nouveauté* à confirmer par la lecture complète des travaux les plus proches, et non une nouveauté établie.

Résumé

Les systèmes fondés sur des grands modèles de langage (LLM) traitent généralement toutes les requêtes avec la même configuration : un même modèle et, le cas échéant, une recherche documentaire (RAG) identique. Cette uniformité gaspille des ressources sur les questions simples et peut dégrader la fiabilité sur les questions difficiles ou non couvertes par les documents. Ce document recense 51 travaux, dont 46 retenus, répartis en cinq axes : le routage et les cascades de modèles, le RAG adaptatif, l'estimation d'incertitude et l'abstention, la mesure du coût énergétique de l'inférence, et les jeux d'évaluation. L'analyse montre que ces trois décisions – *quel modèle*, *faut-il chercher et combien*, *faut-il répondre* – sont le plus souvent étudiées séparément, et que le coût est majoritairement exprimé en prix d'API ou en nombre d'appels plutôt qu'en latence, mémoire ou énergie mesurées sur du matériel local. Nous en déduisons un positionnement possible : une politique de décision *conjointe* et interprétable, évaluée sur machine locale. Des travaux de 2026 réduisent toutefois cet écart, ce qui impose de délimiter précisément la contribution.

Table des matières

1 Introduction **3**

2 Méthode de recherche bibliographique **3**

3 Notions de base **4**

4 Routage et cascades de modèles **4**

5 RAG adaptatif **5**

6 Estimation d'incertitude et abstention **6**

7 Coût, efficacité et énergie de l'inférence **6**

8 Jeux de données et protocoles d'évaluation **7**

9 Tableau comparatif **7**

10 Synthèse et positionnement **8**
10.1 Limites communes des travaux existants 8
10.2 Contribution potentielle 9
10.3 Hypothèses de travail 9
10.4 Travaux dont il faut se distinguer explicitement 9
10.5 Conséquences pour les phases suivantes 9

11 Limites de cette revue et prochaines étapes **9**

A Requêtes de recherche croisée (arXiv, 17/10/2026) **10**

1 Introduction

Contexte. Exécuter un LLM localement présente deux avantages : les données restent sur la machine et le coût est maîtrisé. Les ressources d'un ordinateur personnel sont en revanche limitées en mémoire, en temps de calcul et en énergie. Or toutes les questions ne demandent pas le même effort : certaines sont triviales pour un petit modèle, d'autres exigent un modèle plus puissant, des documents externes, voire un refus de répondre lorsque les preuves manquent.

Problématique. *Comment allouer automatiquement, et de manière mesurable, les ressources de calcul et de recherche documentaire à chaque requête, afin de réduire le coût d'un système LLM local sans dégrader significativement la qualité, la factualité et la fiabilité des réponses ?*

Objectifs de cette revue. Elle doit (i) recenser les approches existantes pour chacune des décisions d'allocation, (ii) identifier les signaux utilisés pour décider, (iii) examiner comment le coût et la fiabilité sont évalués, et (iv) en déduire ce qui distinguerait réellement la méthode envisagée. Le tableau 1 rattache chaque axe aux questions de recherche du cahier des charges.

QR	Question	Axes de la revue
QR1	Peut-on estimer la difficulté d'une question avant de choisir le modèle ou de lancer le RAG ?	§4, §5
QR2	Des signaux d'incertitude et de qualité des preuves permettent-ils de décider quand chercher davantage ou s'abstenir ?	§5, §6
QR3	Quel compromis qualité / latence / mémoire / énergie par rapport à des stratégies fixes ?	§7
QR4	Les gains sont-ils stables selon les types de questions et de documents ?	§8

TABLE 1 – Correspondance entre les questions de recherche et les axes de la revue.

Plan. La section 2 décrit la méthode de recherche bibliographique, la section 3 définit les notions de base, et les sections 4 à 8 présentent chaque axe. La section 9 propose un tableau comparatif, puis la section 10 identifie le manque et formule la contribution potentielle. La section 11 précise les limites de cette revue.

2 Méthode de recherche bibliographique

Sources. arXiv, ACL Anthology, OpenReview, Google Scholar, Semantic Scholar et les actes (proceedings) de NeurIPS, ICLR, AAAI et MLSys. Les références sont gérées dans Zotero.

Requêtes. Elles combinent les concepts du sujet et leurs synonymes : *LLM routing*, *model cascade*, *adaptive retrieval*, *adaptive RAG*, *dynamic RAG*, *uncertainty estimation*, *selective prediction*, *abstention*, *energy-aware LLM inference*. Une recherche ciblée sur arXiv (6 requêtes croisées, menée le 17/10/2026, détaillée en annexe A) a servi à repérer les travaux de 2025–2026 qui combinent plusieurs de ces décisions.

Critères d'inclusion. (i) La méthode adapte, requête par requête, le choix du modèle, la récupération documentaire ou la décision de répondre ; (ii) elle s'accompagne d'une évaluation expérimentale ; ou (iii) l'article fournit une mesure du coût d'inférence ou un jeu de données utile au protocole.

Critères d'exclusion. Optimisation d'infrastructure cloud, architectures matérielles, articles de position sans expérience et systèmes multi-agents hors du cadre questions-réponses.

Processus de sélection.

— 17 références initiales, issues du cahier des charges et d'une première recherche ;

— 26 références ajoutées par recherche ciblée et par *snowballing*, c'est-à-dire en suivant les références citées et citantes ;

— 46 résultats arXiv examinés sur titre lors de la recherche croisée, dont 8 retenus après lecture du résumé ;

— soit **51 références identifiées**, dont **5 exclues** (hors périmètre) et **46 retenues**, classées par thème et par priorité de lecture (P1 à P3).

3 Notions de base

Routage (*routing*)
Choix, avant la génération, du modèle qui traitera une requête parmi plusieurs candidats de tailles ou de coûts différents.

Cascade
Variante séquentielle du routage : on interroge d'abord un modèle peu coûteux, puis on escalade vers un modèle plus puissant si sa réponse semble peu fiable. Le coût du premier modèle est toujours payé.

RAG
Génération augmentée par récupération : des passages extraits d'une base documentaire sont ajoutés au prompt. Le RAG *adaptatif* décide si, quand et combien récupérer.

Incertitude
Estimation de la probabilité qu'une réponse soit incorrecte : probabilités internes, cohérence entre plusieurs réponses échantillonnées, ou confiance exprimée par le modèle.

Abstention
Refus de répondre lorsque le risque d'erreur est jugé trop élevé. On l'évalue par le compromis *couverture / risque* : la part de questions auxquelles le système répond, et le taux d'erreur parmi ces réponses.

Coût
Selon les travaux : prix d'API, nombre d'appels au grand modèle, nombre de tokens, latence, mémoire ou énergie mesurée. Ces mesures ne sont pas interchangeables.

4 Routage et cascades de modèles

Cascades. Chen et al. (2023) distinguent trois leviers pour réduire le coût des LLM : l'adaptation du prompt, l'approximation du LLM et la cascade. Leur instanciation, FrugalGPT, apprend quelles combinaisons de modèles utiliser selon la requête, et rapporte jusqu'à 98 % d'économie à performance égale à celle du meilleur modèle individuel. AutoMix (Aggarwal et al., 2023) escalade vers un modèle plus grand selon une auto-vérification *few-shot* de la réponse du petit modèle ; comme cette auto-vérification est bruitée, la décision est confiée à un routeur fondé sur un processus de décision markovien partiellement observable (POMDP), avec plus de 50 % d'économie à performance comparable. Yue et al. (2023) utilisent comme signal de difficulté la *cohérence* entre plusieurs réponses du petit modèle et atteignent la performance du modèle fort pour 40 % de son coût.

Routage avant génération. Hybrid LLM (Ding et al., 2024) prédit la difficulté de la requête pour l'attribuer à un petit modèle (déployable en périphérie, dit *edge*) ou à un grand modèle. Un seuil de qualité réglable à l'inférence permet d'éviter jusqu'à 40 % des appels au grand modèle sans baisse de qualité. RouteLLM (Ong et al., 2024) entraîne des routeurs fort/faible à partir de données de préférences humaines. Le coût est réduit de plus de moitié dans certains cas, et les

routeurs restent efficaces lorsque la paire de modèles change. D'autres formulations existent : le bandit manchot (Nguyen et al., 2024) ou le routage vers le modèle expert guidé par un modèle de récompense (Lu et al., 2023). RouterBench (Hu et al., 2024) propose un cadre d'évaluation standardisé et un corpus de plus de 405 000 résultats d'inférence.

Travaux récents. Fu et al. (2026) montrent qu'un routage fondé sur le coût d'un appel unique sous-estime le coût réel d'un workflow qui relance les requêtes, jusqu'à un facteur supérieur à 2 sur les tâches difficiles. Ils introduisent un signal de difficulté calculé *localement avant exécution* et sélectionnent le modèle selon le rapport entre précision attendue et coût réel prédit. RACER (Hao et al., 2026) étend un routeur pour produire des *ensembles* de modèles, avec un seuil calibré qui autorise l'abstention et contrôle le risque d'erreur de routage (garanties sans hypothèse sur la distribution des données). La revue de Varangot-Reille et al. (2026) synthétise le domaine et souligne deux limites : la standardisation insuffisante des expériences et la faible prise en compte des coûts non financiers.

Bilan. Ces travaux choisissent *le modèle*, mais ne décident ni de la récupération documentaire ni, à l'exception de RACER, de l'abstention. Le coût y est surtout exprimé en prix d'API ou en nombre d'appels.

5 RAG adaptatif

Quand récupérer ? Mallen et al. (2023) montrent que les LLM retiennent mal les connaissances peu populaires. Récupérer *uniquement lorsque c'est nécessaire* améliore alors à la fois la précision et le coût. Les approches suivantes diffèrent par le signal de décision :

- la connaissance que le modèle a de lui-même, estimée par comparaison avec des questions déjà traitées (SKR, Wang et al., 2023) ;
- la confiance des tokens générés, pour déclencher la récupération en cours de génération (FLARE, Jiang et al., 2023) ;
- une estimation du besoin d'information en temps réel (DRAGIN, Su et al., 2024) ;
- des tokens de réflexion appris par le modèle, ce qui suppose un entraînement spécifique (Self-RAG, Asai et al., 2024).

Selon la complexité de la question. Adaptive-RAG (Jeong et al., 2024) entraîne un petit classifieur qui prédit la complexité d'une requête pour choisir entre trois stratégies : pas de récupération, récupération en une étape, ou récupération itérative. Le système gagne à la fois en efficacité et en précision sur des jeux de questions simples et multi-étapes. C'est la référence la plus directe pour QR1, et son code est public. HyPA-RAG (Kalra et al., 2024) applique la même idée aux paramètres de récupération dans le domaine juridique.

Selon la qualité des preuves. Corrective RAG (Yan et al., 2024) évalue la qualité des documents récupérés avec un évaluateur léger, puis déclenche une action selon le résultat : utiliser les documents, les compléter par une recherche web, ou les filtrer. Tiny-Critic RAG (Wu et al., 2026) confie ce rôle de contrôle à un petit modèle adapté par LoRA (adaptation à faible rang), avec une latence réduite d'un ordre de grandeur par rapport à un grand évaluateur.

Incertitude contre pipelines complexes. Moskvoretskii et al. (2025) comparent 35 méthodes (8 méthodes de récupération adaptative et 27 estimateurs d'incertitude) sur 6 jeux de données et 10 métriques. Les estimateurs d'incertitude simples font souvent mieux que les pipelines complexes en efficacité, pour une qualité comparable. Ce résultat justifie de privilégier des *signaux simples et interprétables*. Self-Routing RAG (Wu et al., 2025) généralise la décision binaire « récupérer ou non

» en un choix de *source de connaissance*, dans lequel le LLM lui-même est une source. Avec des modèles de taille 7B, il réduit de 21 à 40 % le nombre de récupérations.

Routage entre paradigmes de RAG. RAGRouter-Bench (Wang et al., 2026) formule le choix d'un paradigme de RAG comme un problème de routage dépendant de la paire requête–corpus. Il évalue conjointement la qualité et la consommation de ressources avec plusieurs LLM, et conclut qu'aucun paradigme n'est optimal partout. Sur ce benchmark, un simple classifieur TF-IDF + SVM simule 28 % d'économie de tokens (Bansal and Agarwal, 2026). Pre-Route (Chen et al., 2026b) choisit de façon analogue entre RAG et contexte long.

Réduire le contexte. LeanContext (Arefeen et al., 2024) réduit le contexte récupéré aux phrases clés : le coût baisse de 37 à 68 % pour une perte de 1,4 à 2,7 % de ROUGE-1. Ce compromis chiffré est du même ordre que le critère de succès du projet. Clustered RAG (Akesson and Santos, 2024) et LogicRAG (Chen et al., 2026a) réduisent eux aussi les tokens de contexte.

Bilan. Le RAG adaptatif décide *si et comment récupérer*, généralement avec *un seul modèle générateur*. L'abstention y est rarement une sortie explicite, et le coût y est le plus souvent mesuré en nombre de récupérations ou d'appels.

6 Estimation d'incertitude et abstention

Estimer l'incertitude. Trois familles de signaux se distinguent.

- *Probabilités internes.* Kadavath et al. (2022) montrent que les grands modèles sont souvent bien calibrés lorsqu'on leur demande d'évaluer leurs propres réponses (P(True)). La probabilité « je connais la réponse », P(IK), augmente en présence de sources pertinentes, ce qui en fait un signal candidat pour décider de récupérer.
- *Cohérence entre plusieurs échantillons.* L'entropie sémantique (Kuhn et al., 2023) regroupe les réponses échantillonnées qui ont le même sens ; SelfCheckGPT (Manakul et al., 2023) détecte les hallucinations par contradiction entre échantillons. Ces signaux sont efficaces mais exigent *plusieurs générations* par question.
- *Confiance verbalisée.* Le modèle exprime sa propre confiance en mots ; elle n'est calibrée qu'après un apprentissage dédié (Lin et al., 2022).

S'abstenir. Kamath et al. (2020) formalisent la réponse sélective sous changement de domaine. Les probabilités *softmax* sont trop confiantes hors domaine, alors qu'un calibrateur appris améliore nettement la couverture à précision fixée. La revue de Wen et al. (2024) organise les méthodes, benchmarks et métriques d'abstention selon trois perspectives : la requête, le modèle et les valeurs humaines.

Bilan. Le coût de l'estimation d'incertitude elle-même est rarement intégré à la décision. Pourtant, échantillonner plusieurs réponses avec un petit modèle peut coûter plus cher qu'un appel direct à un modèle plus grand. Ce point concerne directement QR2 et QR3.

7 Coût, efficacité et énergie de l'inférence

Samsi et al. (2023) mesurent l'énergie de l'inférence de LLaMA selon la taille du modèle, sur des GPU de centre de données (V100, A100). Luccioni et al. (2022) estiment l'empreinte carbone de BLOOM sur l'ensemble de son cycle de vie, et Luccioni et al. (2024) comparent le coût énergétique de l'inférence de nombreux modèles et tâches : les modèles génératifs généralistes s'y révèlent beaucoup plus coûteux que les modèles spécialisés.

Bilan. Ces travaux *mesurent* l'énergie mais ne l'*optimisent* pas par des décisions prises requête par requête. Ils portent en outre sur du matériel de centre de données. Inversement, les travaux de routage optimisent un coût qui n'est presque jamais énergétique. Le cahier des charges impose une précaution que la littérature confirme : ne pas déduire une énergie exacte du seul temps CPU, et rapporter séparément les indicateurs indirects (latence, tokens, mémoire).

8 Jeux de données et protocoles d'évaluation

Les jeux de données recensés couvrent les catégories de questions demandées par le cahier des charges (tableau 2).

Catégorie	**Jeux de données**
Simple	SQuAD (questions avec réponse) (Rajpurkar et al., 2018)
Complexe / multi-étapes	HotpotQA, avec phrases justificatives (Yang et al., 2018) ; MuSiQue (Trivedi et al., 2022)
Non couverte par les documents	SQuAD 2.0 (Rajpurkar et al., 2018) ; MuSiQue-Full (questions sans réponse)
Types variés, hallucinations pénalisées	CRAG Benchmark (Yang et al., 2024)
Routage entre paradigmes de RAG	RAGRouter-Bench (Wang et al., 2026)

TABLE 2 – Jeux de données utilisables pour le benchmark du projet (Phase 2).

Leçons méthodologiques. (i) Li et al. (2026) montrent que des signaux issus de la récupération, pourtant corrélés à l'utilité d'une étape supplémentaire, n'améliorent pas de façon fiable un routeur fondé sur la seule requête. Tout signal ajouté doit donc être comparé à un *contrôle « requête seule »* apparié. (ii) RouterBench et RAGRouter-Bench évaluent la qualité et le coût conjointement, sous forme de compromis, plutôt qu'avec une seule métrique. (iii) Adaptive-RAG s'évalue sur SQuAD, HotpotQA et MuSiQue : réutiliser ces jeux permet une comparaison directe.

9 Tableau comparatif

Le tableau 3 situe les travaux les plus proches selon les trois décisions d'allocation, le signal utilisé, la nature du coût évalué et le cadre d'exécution.

Travail	Choix du modèle	Décision RAG	Abstention	Signal de décision	Coût évalué	Local
FrugalGPT (2023)	✓	✗	✗	Scoreur appris (après génération)	Prix API	✗
Hybrid LLM (2024)	✓	✗	✗	Difficulté prédite (avant)	Appels au grand modèle	∼
RouteLLM (2024)	✓	✗	✗	Préférences humaines	Prix / appels	✗
AutoMix (2023)	✓	✗	✗	Auto-vérification (après)	Calcul	✗
Fu et al. (2026)	✓	✗	✗	Entropie de branchement (avant, locale)	Tokens réels	∼
RACER (2026)	✓	✗	✓	Score calibré	Taille d'ensemble	✗
Mallen et al. (2023)	✗	✓	✗	Popularité de l'entité	Inférence	✗
Adaptive-RAG (2024)	✗	✓	✗	Complexité (classifieur)	Temps, étapes	✗
Corrective RAG (2024)	✗	✓	✗	Qualité des documents	–	✗
Moskvoretskii et al. (2025)	✗	✓	✗	Incertitude (27 méthodes)	Appels, récupérations	✗
SR-RAG (2025)	✗	✓	✗	Incertitude + mémoire de politiques	Récupérations, latence	∼
RAGRouter-Bench (2026)	∼	✓	✗	Compatibilité requête–corpus	Ressources	✗
Kamath et al. (2020)	✗	✗	✓	Calibrateur appris	–	✗
Samsi et al. (2023)	✗	✗	✗	(mesure seulement)	Énergie GPU	✗
Projet visé	✓	✓	✓	**Signaux peu coûteux, coût du signal compté**	**Latence, mémoire, énergie**	✓

TABLE 3 – Positionnement des travaux les plus proches. ✓ : traité ; ✗ : non traité ; ∼ : partiellement (par exemple des modèles 7B exécutables localement, sans évaluation en contexte local). Grille établie à partir des résumés, à confirmer à la lecture.

10 Synthèse et positionnement

10.1 Limites communes des travaux existants

1. **Des décisions isolées.** Le routage choisit le modèle, le RAG adaptatif choisit la récupération et l'abstention est étudiée à part. Aucun des travaux recensés ne choisit *conjointement* les trois dans une même politique (tableau 3).
2. **Un coût surtout financier.** Le coût est surtout exprimé en prix d'API ou en nombre d'appels ; la latence, la mémoire et l'énergie mesurées sur machine locale sont rarement rapportées, une limite que souligne aussi Varangot-Reille et al. (2026).
3. **Le coût du signal est ignoré.** Les signaux d'incertitude les plus performants exigent plusieurs générations, et leur coût est rarement retranché du gain.
4. **Une évaluation parfois optimiste.** Certains gains disparaissent face à un contrôle « requête seule » (Li et al., 2026), et une moyenne globale peut masquer des dégradations sur les questions difficiles.

10.2 Contribution potentielle

Concevoir et évaluer une **politique de décision conjointe et interprétable** qui choisit, pour chaque requête, **la taille du modèle**, **le niveau de récupération documentaire** (aucune, simple, complémentaire) et **la décision de répondre ou de s'abstenir**. Cette politique s'appuie sur des signaux peu coûteux **dont le coût est lui-même comptabilisé**, et elle est évaluée **sur du matériel local** en qualité, factualité, couverture/risque, latence, mémoire et, si mesurable, énergie.

10.3 Hypothèses de travail

H1 (QR1)
Un signal de difficulté calculé avant génération et à faible coût suffit à orienter une part significative des requêtes vers le petit modèle, sans RAG, sans perte de qualité au-delà de la marge fixée.

H2 (QR2)
Combiner un signal d'incertitude du modèle et un score de suffisance des preuves améliore le compromis couverture/risque par rapport à chacun des deux signaux pris séparément.

H3 (QR3)
La politique conjointe domine les stratégies fixes sur la courbe qualité–coût (latence, tokens et mémoire), une fois le coût de ses propres signaux inclus.

H4 (QR4)
Les gains varient selon la catégorie de question ; ils seront rapportés par catégorie, pas seulement en moyenne.

10.4 Travaux dont il faut se distinguer explicitement

Travail	Ce qu'il fait déjà	Ce qui reste ouvert
Adaptive-RAG	Complexité → stratégie de RAG	Choix du modèle, abstention, mesure locale
Moskvoretskii et al.	Signaux d'incertitude simples pour décider du RAG	Plusieurs tailles de modèle, abstention, énergie
RAGRouter-Bench	Routage entre paradigmes de RAG avec coût en ressources	Abstention, matériel local, politique conjointe modèle × RAG
Fu et al. (2026)	Signal local avant exécution, coût réel	RAG adaptatif, abstention
RACER	Routage avec abstention calibrée	RAG, coût local

10.5 Conséquences pour les phases suivantes

— **Benchmark (Phase 2).** Reprendre SQuAD/SQuAD 2.0, HotpotQA et MuSiQue pour pouvoir se comparer à Adaptive-RAG ; étudier l'intérêt de RAGRouter-Bench.

— **Baselines (Phase 3).** En plus des baselines A, B et C du cahier des charges, ajouter Adaptive-RAG (code public), un routeur fondé sur la seule requête (contrôle de Li et al., 2026), et si possible un seuil d'incertitude simple (dans l'esprit de Moskvoretskii et al., 2025).

— **Métriques (Phase 2).** Courbes qualité–coût ; couverture/risque pour l'abstention ; résultats par catégorie ; coût des signaux inclus dans le coût total.

11 Limites de cette revue et prochaines étapes

— **Pré-analyse.** L'analyse repose sur les résumés ; les cellules du tableau 3 et les limites attribuées aux travaux doivent être confirmées par la lecture complète.

— **Couverture.** La recherche croisée a porté surtout sur arXiv ; elle doit être complétée par ACL Anthology, Semantic Scholar et le *snowballing* à partir de RAGRouter-Bench, SR-RAG et RACER.

— **Prépublications.** Plusieurs travaux de 2025–2026 ne sont pas encore évalués par les pairs et peuvent évoluer.

— **Un domaine très actif.** Une veille (alertes de citation) est nécessaire jusqu'à la soumission ; le positionnement devra être revérifié juste avant.

Prochaines étapes. (1) Lecture approfondie des travaux P1 et des cinq travaux du tableau de distinction ; (2) mise à jour de cette revue (v0.2) ; (3) consolidation de la formulation de la contribution, idéalement après relecture par un enseignant-chercheur ; (4) passage à la Phase 2 (benchmark et protocole).

A Requêtes de recherche croisée (arXiv, 17/10/2026)

Requête (champ résumé / titre)	**Résultats examinés**
`abs:routing AND abs:retrieval AND abs:small AND abs:large AND abs:LLM`	12
`abs:"adaptive retrieval" AND abs:"model selection"`	0
`ti:RAG AND ti:rout*`	12
`abs:"retrieval-aware" AND abs:routing`	1
`abs:abstention AND abs:routing AND abs:LLM`	12
`abs:energy AND abs:routing AND abs:"retrieval-augmented"`	9
Total examiné sur titre / retenus après résumé	**46 / 8**

Références

Pranjal Aggarwal, Aman Madaan, Ankit Anand, Srividya Pranavi Potharaju, Swaroop Mishra, Pei Zhou, Aditya Gupta, Dheeraj Rajagopal, Karthik Kappaganthu, Yiming Yang, Shyam Upadhyay, Manaal Faruqui, and Mausam. AutoMix : Automatically Mixing Language Models. arXiv preprint arXiv :2310.12963, 2023. URL https://arxiv.org/abs/2310.12963.

Simon Akesson and Frances A. Santos. Clustered Retrieved Augmented Generation (CRAG). arXiv preprint arXiv :2406.00029, 2024. URL https://arxiv.org/abs/2406.00029.

Md Adnan Arefeen, Biplob Debnath, and Srimat Chakradhar. LeanContext : Cost-efficient domain-specific question answering using LLMs. *Natural Language Processing Journal*, 2024. doi : 10.1016/j.nlp.2024.100065.

Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. Self-RAG : Learning to Retrieve, Generate, and Critique through Self-Reflection. In *International Conference on Learning Representations (ICLR)*, 2024. URL https://arxiv.org/abs/2310.11511.

Prakhar Bansal and Shivangi Agarwal. Lightweight Query Routing for Adaptive RAG : A Baseline Study on RAGRouter-Bench. arXiv preprint arXiv :2604.03455, 2026. URL https://arxiv.org/abs/2604.03455.

Lingjiao Chen, Matei Zaharia, and James Zou. FrugalGPT : How to Use Large Language Models While Reducing Cost and Improving Performance. arXiv preprint arXiv :2305.05176, 2023. URL https://arxiv.org/abs/2305.05176.

Shengyuan Chen, Chuang Zhou, Zheng Yuan, Qinggang Zhang, Zeyang Cui, Hao Chen, Yilin Xiao, Jiannong Cao, and Xiao Huang. You Don't Need Pre-Built Graphs for RAG : Retrieval Augmented

Generation with Adaptive Reasoning Structures. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2026a. doi : 10.1609/aaai.v40i36.40278.

Yiwen Chen, Kuan Li, Fuzhen Zhuang, Deqing Wang, Zhao Zhang, Liwen Zhang, Yong Jiang, Shuai Wang, and Minhao Cheng. Route Before Retrieve : Activating Latent Routing Abilities of LLMs for RAG vs. Long-Context Selection. arXiv preprint arXiv :2605.10235, 2026b. URL https://arxiv.org/abs/2605.10235.

Dujian Ding, Ankur Mallick, Chi Wang, Robert Sim, Subhabrata Mukherjee, Victor Ruhle, Laks V. S. Lakshmanan, and Ahmed Hassan Awadallah. Hybrid LLM : Cost-Efficient and Quality-Aware Query Routing. In *International Conference on Learning Representations (ICLR)*, 2024. URL https://arxiv.org/abs/2404.14618.

Heming Fu, Shan Lin, Qianqian Xie, and Guojun Xiong. Not All Tokens Are Equal : Inflation-Aware Routing for Agentic LLM Systems. arXiv preprint arXiv :2608.13571, 2026. URL https://arxiv.org/abs/2608.13571.

Sai Hao, Hao Zeng, Hongxin Wei, and Bingyi Jing. RACER : Risk-Aware Calibrated Efficient Routing for Large Language Models. arXiv preprint arXiv :2603.06616, 2026. URL https://arxiv.org/abs/2603.06616.

Qitian Jason Hu, Jacob Bieker, Xiuyu Li, Nan Jiang, Benjamin Keigwin, Gaurav Ranganath, Kurt Keutzer, and Shriyash Kaustubh Upadhyay. RouterBench : A Benchmark for Multi-LLM Routing System. arXiv preprint arXiv :2403.12031, 2024. URL https://arxiv.org/abs/2403.12031.

Soyeong Jeong, Jinheon Baek, Sukmin Cho, Sung Ju Hwang, and Jong C. Park. Adaptive-RAG : Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity. In *Proceedings of NAACL-HLT 2024*, 2024. URL https://arxiv.org/abs/2403.14403.

Zhengbao Jiang, Frank F. Xu, Luyu Gao, Zhiqing Sun, Qian Liu, Jane Dwivedi-Yu, Yiming Yang, Jamie Callan, and Graham Neubig. Active Retrieval Augmented Generation. In *Proceedings of EMNLP 2023*, 2023. URL https://arxiv.org/abs/2305.06983.

Saurav Kadavath, Tom Conerly, Amanda Askell, Tom Henighan, Dawn Drain, Ethan Perez, Nicholas Schiefer, Zac Hatfield-Dodds, Nova DasSarma, Eli Tran-Johnson, Scott Johnston, Sheer El-Showk, Andy Jones, Nelson Elhage, Tristan Hume, Anna Chen, Yuntao Bai, Sam Bowman, Stanislav Fort, Deep Ganguli, Danny Hernandez, Josh Jacobson, Jackson Kernion, Shauna Kravec, Liane Lovitt, Kamal Ndousse, Catherine Olsson, Sam Ringer, Dario Amodei, Tom Brown, Jack Clark, Nicholas Joseph, Ben Mann, Sam McCandlish, Chris Olah, and Jared Kaplan. Language Models (Mostly) Know What They Know. arXiv preprint arXiv :2207.05221, 2022. URL https://arxiv.org/abs/2207.05221.

Rishi Kalra, Zekun Wu, Ayesha Gulley, Airlie Hilliard, Xin Guan, Adriano Koshiyama, and Philip Colin Treleaven. HyPA-RAG : A Hybrid Parameter Adaptive Retrieval-Augmented Generation System for AI Legal and Policy Applications. In *Proceedings of the 1st Workshop on Customizable NLP (CustomNLP4U)*, 2024. doi : 10.18653/v1/2024.customnlp4u-1.18.

Amita Kamath, Robin Jia, and Percy Liang. Selective Question Answering under Domain Shift. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020. URL https://arxiv.org/abs/2006.09462.

Lorenz Kuhn, Yarin Gal, and Sebastian Farquhar. Semantic Uncertainty : Linguistic Invariances for Uncertainty Estimation in Natural Language Generation. In *International Conference on Learning Representations (ICLR)*, 2023. URL https://arxiv.org/abs/2302.09664.

Qiaomu Li, Qiuyuan Zhang, and Nong Ming. Beyond the Query : Do Retrieval Signals Improve Adaptive Multimodal RAG Routing ? arXiv preprint arXiv :2609.12437, 2026. URL https://arxiv.org/abs/2609.12437.

Stephanie Lin, Jacob Hilton, and Owain Evans. Teaching Models to Express Their Uncertainty in Words. *Transactions on Machine Learning Research*, 2022. URL https://arxiv.org/abs/2205.14334.

Keming Lu, Hongyi Yuan, Runji Lin, Junyang Lin, Zheng Yuan, Chang Zhou, and Jingren Zhou. Routing to the Expert : Efficient Reward-guided Ensemble of Large Language Models. arXiv preprint arXiv :2311.08692, 2023. URL https://arxiv.org/abs/2311.08692.

Alexandra Sasha Luccioni, Sylvain Viguier, and Anne-Laure Ligozat. Estimating the Carbon Footprint of BLOOM, a 176B Parameter Language Model. arXiv preprint arXiv :2211.02001, 2022. URL https://arxiv.org/abs/2211.02001.

Alexandra Sasha Luccioni, Yacine Jernite, and Emma Strubell. Power Hungry Processing : Watts Driving the Cost of AI Deployment ? In *ACM Conference on Fairness, Accountability, and Transparency (FAccT)*, 2024. URL https://arxiv.org/abs/2311.16863.

Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Daniel Khashabi, and Hannaneh Hajishirzi. When Not to Trust Language Models : Investigating Effectiveness of Parametric and Non-Parametric Memories. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*, 2023. URL https://arxiv.org/abs/2212.10511.

Potsawee Manakul, Adian Liusie, and Mark J. F. Gales. SelfCheckGPT : Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models. In *Proceedings of EMNLP 2023*, 2023. URL https://arxiv.org/abs/2303.08896.

Viktor Moskvoretskii, Maria Lysyuk, Mikhail Salnikov, Nikolay Ivanov, Sergey Pletenev, Daria Galimzianova, Nikita Krayko, Vasily Konovalov, Irina Nikishina, and Alexander Panchenko. Adaptive Retrieval Without Self-Knowledge ? Bringing Uncertainty Back Home. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2025. URL https://arxiv.org/abs/2501.12835.

Quang H. Nguyen, Thinh Dao, Duy C. Hoang, Juliette Decugis, Saurav Manchanda, Nitesh V. Chawla, and Khoa D. Doan. MetaLLM : A High-performant and Cost-efficient Dynamic Framework for Wrapping LLMs. arXiv preprint arXiv :2407.10834, 2024. URL https://arxiv.org/abs/2407.10834.

Isaac Ong, Amjad Almahairi, Vincent Wu, Wei-Lin Chiang, Tianhao Wu, Joseph E. Gonzalez, M Waleed Kadous, and Ion Stoica. RouteLLM : Learning to Route LLMs with Preference Data. arXiv preprint arXiv :2406.18665, 2024. URL https://arxiv.org/abs/2406.18665.

Pranav Rajpurkar, Robin Jia, and Percy Liang. Know What You Don't Know : Unanswerable Questions for SQuAD. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2018. URL https://arxiv.org/abs/1806.03822.

Siddharth Samsi, Dan Zhao, Joseph McDonald, Baolin Li, Adam Michaleas, Michael Jones, William Bergeron, Jeremy Kepner, Devesh Tiwari, and Vijay Gadepally. From Words to Watts : Benchmarking the Energy Costs of Large Language Model Inference. arXiv preprint arXiv :2310.03003, 2023. URL https://arxiv.org/abs/2310.03003.

Weihang Su, Yichen Tang, Qingyao Ai, Zhijing Wu, and Yiqun Liu. DRAGIN : Dynamic Retrieval Augmented Generation based on the Information Needs of Large Language Models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024. URL https://arxiv.org/abs/2403.10081.

Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot, and Ashish Sabharwal. MuSiQue : Multihop Questions via Single-hop Question Composition. *Transactions of the Association for Computational Linguistics*, 2022. URL https://arxiv.org/abs/2108.00573.

Clovis Varangot-Reille, Christophe Bouvard, Antoine Gourru, Mathieu Ciancone, Marion Schaeffer, and François Jacquenet. Doing More with Less : A Survey on Routing Strategies for Resource Optimisation in Large Language Model-Based Systems. *Journal of Artificial Intelligence Research*, 2026. URL https://arxiv.org/abs/2502.00409.

Yile Wang, Peng Li, Maosong Sun, and Yang Liu. Self-Knowledge Guided Retrieval Augmentation for Large Language Models. arXiv preprint arXiv :2310.05002, 2023. URL https://arxiv.org/abs/2310.05002.

Ziqi Wang, Xi Zhu, Shuhang Lin, Haochen Xue, Minghao Guo, and Yongfeng Zhang. RAGRouter-Bench : A Dataset and Benchmark for Adaptive RAG Routing. arXiv preprint arXiv :2602.00296, 2026. URL https://arxiv.org/abs/2602.00296.

Bingbing Wen, Jihan Yao, Shangbin Feng, Chenjun Xu, Yulia Tsvetkov, Bill Howe, and Lucy Lu Wang. Know Your Limits : A Survey of Abstention in Large Language Models. arXiv preprint arXiv :2407.18418, 2024. URL https://arxiv.org/abs/2407.18418.

Di Wu, Jia-Chen Gu, Kai-Wei Chang, and Nanyun Peng. Self-Routing RAG : Binding Selective Retrieval with Knowledge Verbalization. arXiv preprint arXiv :2504.01018, 2025. URL https://arxiv.org/abs/2504.01018.

Yichao Wu, Penghao Liang, Yafei Xiang, Mengwei Yuan, Jianan Liu, Jing Yang, Xianyou Li, and Weiran Yan. Tiny-Critic RAG : Empowering Agentic Fallback with Parameter-Efficient Small Language Models. arXiv preprint arXiv :2603.00846, 2026. URL https://arxiv.org/abs/2603.00846.

Shi-Qi Yan, Jia-Chen Gu, Yun Zhu, and Zhen-Hua Ling. Corrective Retrieval Augmented Generation. arXiv preprint arXiv :2401.15884, 2024. URL https://arxiv.org/abs/2401.15884.

Xiao Yang, Kai Sun, Hao Xin, Yushi Sun, Nikita Bhalla, Xiangsen Chen, Sajal Choudhary, Rongze Daniel Gui, Ziran Will Jiang, Ziyu Jiang, Lingkun Kong, Brian Moran, Jiaqi Wang, Yifan Ethan Xu, An Yan, Chenyu Yang, Eting Yuan, Hanwen Zha, Nan Tang, Lei Chen, Nicolas Scheffer, Yue Liu, Nirav Shah, Rakesh Wanga, Anuj Kumar, Wen tau Yih, and Xin Luna Dong. CRAG – Comprehensive RAG Benchmark. In *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2024. URL https://arxiv.org/abs/2406.04744.

Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William W. Cohen, Ruslan Salakhutdinov, and Christopher D. Manning. HotpotQA : A Dataset for Diverse, Explainable Multi-hop Question Answering. In *Proceedings of EMNLP 2018*, 2018. URL https://arxiv.org/abs/1809.09600.

Murong Yue, Jie Zhao, Min Zhang, Liang Du, and Ziyu Yao. Large Language Model Cascades with Mixture of Thoughts Representations for Cost-efficient Reasoning. arXiv preprint arXiv :2310.03094, 2023. URL https://arxiv.org/abs/2310.03094.