Livrable L3 – Méthodes de référence

Allocation adaptative des ressources de calcul et de recherche documentaire pour des systèmes LLM locaux, économes et fiables

Choix de la recherche documentaire, gel du protocole, routeurs de référence

Alae Lahbichi – Étudiant en 5e année IA/Data

a.lahbichi2004@gmail.com

Dépôt GitHub : AlaeLahbichi/Adaptive-Compute-and-RAG-for-Efficient-Reliable-Local-LLMs

18 octobre 2026

Résumé

Cette partie construit les adversaires que la méthode adaptative (Partie IV) devra battre. D'abord, trois méthodes de recherche documentaire sont comparées sur le jeu de développement. La recherche lexicale BM25 l'emporte nettement sur la recherche dense du pilote : son rappel@3 passe de 0,60 à 0,82 sur les questions simples et de 0,22 à 0,37 sur les questions complexes, et elle est 40 fois plus rapide. Elle est retenue, et le protocole est gelé (étiquette `protocole-v1.0`). Ensuite, six stratégies fixes (A à F) sont exécutées, puis deux routeurs de référence fondés sur le seul texte de la question sont évalués par validation croisée : un routeur coût–qualité qui choisit parmi les six stratégies (R1, contrôle exigé par la revue L1) et une version simplifiée d'Adaptive-RAG (R2). Avec la recherche BM25, la référence B (grand modèle + 3 passages) passe de 0,42 à 0,54 de score global. Aucun des deux routeurs ne satisfait le critère principal. R1, au réglage 20 % plus rapide que B, perd 11,6 points ; R2 reste proche de B en qualité (−1,9 point) mais ne gagne que 8 % de latence. Un routeur parfait (oracle) atteindrait pourtant 0,76 en 0,40 s. Lire la seule question ne suffit donc pas : il faut des signaux plus informatifs, ce que la Partie IV devra apporter.

Table des matières

1 Rôle de cette partie **3**

2 Choix de la recherche documentaire **3**

3 Les six stratégies fixes avec la recherche BM25 **4**

4 Routeurs de référence **4**

4.1 Principe commun 4

4.2 R1 – Routeur « question seule » (contrôle) 4

4.3 R2 – Adaptive-RAG simplifié 5

5 Résultats **5**

6 Ce que la méthode adaptative devra démontrer **6**

7 Limites **6**

A Reproduire **6**

1 Rôle de cette partie

Une méthode ne se juge qu'à l'aune de ce qui existe déjà. La Partie II a fixé l'épreuve (questions, métriques, critères de succès) ; la Partie III installe des *concurrents de référence* sérieux, pour qu'un éventuel gain de la Partie IV ne puisse pas être attribué à des comparaisons trop faciles. Trois objectifs :

1. **Fixer la recherche documentaire**, maillon faible relevé au pilote, puis geler le protocole.
2. **Mesurer ce qu'obtient un routeur qui ne lit que la question** (R1). La revue L1 a montré que des signaux plus coûteux n'apportent souvent rien de plus qu'un tel contrôle (Li et al., 2026).
3. **Reproduire le travail publié le plus proche**, Adaptive-RAG (Jeong et al., 2024), sous une forme simplifiée et dans nos conditions (R2).

Tout est réglé et évalué sur le **jeu de développement** (180 questions). Le jeu de test reste intact.

2 Choix de la recherche documentaire

Méthodes comparées.

— **Dense** (pilote) : embeddings MiniLM et similarité cosinus, qui compare le *sens*.

— **BM25** : score lexical Okapi ($k_1 = 1{,}5$, $b = 0{,}75$, mots vides retirés), qui compare les *mots* ; implémenté directement avec une matrice creuse.

— **Hybride** : fusion des deux classements par la somme des inverses des rangs (*Reciprocal Rank Fusion*, constante 60).

	Simple			Complexe			
Méthode	@1	@3	@6	@1	@3	@6	**Temps / requête**
Dense	0,48	0,60	0,70	0,00	0,22	0,35	7,4 ms
BM25	**0,65**	**0,82**	**0,87**	0,00	**0,37**	**0,50**	**0,2 ms**
Hybride	0,60	0,72	0,80	0,00	0,33	0,48	7,1 ms

TABLE 1 – Rappel de la recherche sur le jeu de développement (60 questions par catégorie). Pour une question complexe, les deux passages justificatifs doivent être récupérés : le rappel@1 est donc nul par construction. Questions non couvertes (rappel du paragraphe d'origine, @1 / @3 / @6) : dense 0,52 / 0,68 / 0,77 ; BM25 0,73 / 0,83 / 0,87 ; hybride 0,65 / 0,90 / 0,97.

Décision. BM25 est retenu. Sur les questions qui ont une réponse (simples et complexes), il domine les deux autres méthodes à chaque profondeur, tout en étant 40 fois plus rapide et sans modèle d'embeddings à exécuter. Sur les questions non couvertes, la recherche hybride retrouve plus souvent le paragraphe d'origine (rappel@3 de 0,90 contre 0,83). Ce critère compte moins pour elles, car le comportement attendu est de s'abstenir et le paragraphe d'origine ne contient pas la réponse. Ce résultat s'explique par la nature des questions, riches en noms propres et en termes repris du texte source, et par la faiblesse relative du petit modèle d'embeddings multilingue. La fusion hybride, à poids égaux, est tirée vers le bas par la composante dense.

Gel du protocole. Le fichier `configs/protocole_v1.json` (version 1.0) consigne ce choix ainsi que deux stratégies supplémentaires à 6 passages, E et F, qui complètent l'espace de décision annoncé dans L2. L'étiquette Git `protocole-v1.0` fige cet état. Les empreintes des données (`MANIFEST.json`) sont inchangées depuis L2.

3 Les six stratégies fixes avec la recherche BM25

Stratégie	Score	IC 95 %	Simple	Complexe	Non couv.	Couv.	Risque	Latence
A – grand, 0 passage	0,312	[0,248 ; 0,378]	0,07	0,09	0,78	0,31	0,82	0,25 s
B – grand, 3 passages	**0,541**	[0,472 ; 0,610]	0,68	0,36	0,58	0,62	0,39	0,92 s
C – petit, 0 passage	0,233	[0,174 ; 0,294]	0,05	0,07	0,58	0,46	0,93	0,13 s
D – petit, 3 passages	0,330	[0,267 ; 0,397]	0,48	0,29	0,22	0,83	0,69	0,37 s
E – grand, 6 passages	0,570	[0,501 ; 0,637]	0,70	0,45	0,57	0,67	0,40	1,63 s
F – petit, 6 passages	0,372	[0,308 ; 0,439]	0,53	0,37	0,22	0,89	0,66	0,62 s

TABLE 2 – Stratégies fixes avec la recherche BM25 (jeu de développement, 180 questions). Les colonnes Simple, Complexe et Non couv. donnent le score global par catégorie.

Effet du changement de recherche (par rapport au pilote de L2). Les stratégies avec RAG progressent nettement : B passe de 0,424 à 0,541 (+11,7 points) et devient un peu plus rapide (0,99 à 0,92 s), car BM25 coûte moins cher que l'encodage de la question. D passe de 0,298 à 0,330. Les stratégies sans recherche (A, C) sont inchangées, comme attendu. La référence des critères de succès est donc *plus exigeante* qu'au pilote.

Six passages plutôt que trois. E améliore B de 2,9 points, surtout sur les questions complexes (0,45 contre 0,36), mais coûte 76 % de latence en plus. L'écart avec B n'est pas significatif (IC 95 % de la différence : $[-1{,}1; +7{,}1]$ points). Une recherche plus large n'est donc utile que pour une partie des questions, ce qui justifie de la décider question par question.

4 Routeurs de référence

4.1 Principe commun

Les deux routeurs ne lisent *que le texte de la question*, sans générer ni rechercher au préalable. Leurs caractéristiques sont un TF-IDF sur les mots et les paires de mots, complété de quelques indicateurs simples (longueur, nombre de mots en majuscule, présence de chiffres, de « and » ou « both », mot interrogatif initial). Comme la génération est déterministe, la réponse d'un routeur à une question est celle de la stratégie qu'il choisit, déjà calculée en section 3. Le temps de calcul du routeur est mesuré et ajouté à la latence.

Validation croisée. Avec 180 questions, les routeurs sont entraînés et évalués par validation croisée en 5 plis stratifiés par catégorie : chaque question est routée par un modèle qui ne l'a jamais vue. Les résultats restent toutefois *optimistes* : les hyperparamètres et le point de fonctionnement de R1 sont choisis sur ce même jeu de développement. Seule l'évaluation finale sur le jeu de test donnera une mesure non biaisée.

4.2 R1 – Routeur « question seule » (contrôle)

Pour chaque stratégie $s \in \{A, \dots, F\}$, une régression ridge prédit le score $\hat{y}_s(q)$ à partir de la question q. Le routeur choisit

$$s^\star(q) = \arg\max_s \ \hat{y}_s(q) - \lambda\, \bar{t}_s,$$

où $\bar{t}_s$ est la latence moyenne de la stratégie s sur les plis d'apprentissage. Le paramètre $\lambda \geq 0$ règle le compromis : $\lambda = 0$ privilégie la qualité, un grand λ privilégie la vitesse. On fait varier λ pour tracer une courbe qualité–coût, dans l'esprit de Hybrid LLM (Ding et al., 2024). Le point rapporté est le meilleur score parmi les réglages au moins 20 % plus rapides que B, c'est-à-dire ceux qui satisfont la contrainte de latence du critère principal.

4.3 R2 – Adaptive-RAG simplifié

Comme dans Jeong et al. (2024), un classifieur de complexité choisit, avec un modèle fixe (le grand), entre aucune recherche (A), une recherche de 3 passages (B) et une recherche complémentaire de 6 passages (E). L'étiquette d'apprentissage d'une question est la stratégie la plus simple qui répond correctement. Si aucune ne répond correctement, on reprend le biais par jeu de données de l'article original : B pour SQuAD (une étape), E pour HotpotQA (plusieurs étapes). Le classifieur est une régression logistique multinomiale. Deux simplifications par rapport à l'original sont assumées : le classifieur est linéaire au lieu d'un modèle T5 affiné, et la recherche itérative est remplacée par une recherche unique plus large.

5 Résultats

Méthode	Score	Écart à B	IC 95 %	Latence	Gain vs B	Couv.	Risque
B – référence	0,541	–	–	0,92 s	–	0,62	0,39
R1 – question seule	0,425	−11,6	[−18,5; −4,8]	0,74 s	20 %	0,58	0,57
R2 – Adaptive-RAG simplifié	0,522	−1,9	[−7,4; +3,3]	0,85 s	8 %	0,49	0,39
Oracle (A–F)	*0,762*	+22,1	[+16,5; +27,8]	*0,40 s*	*56 %*	0,58	0,19

TABLE 3 – Routeurs de référence, validation croisée en 5 plis sur le jeu de développement. Surcoût de calcul des routeurs inclus dans la latence : 0,5 ms pour R1, 0,3 ms pour R2. Écarts en points de score ; R1 au réglage $\lambda = 0{,}113$.

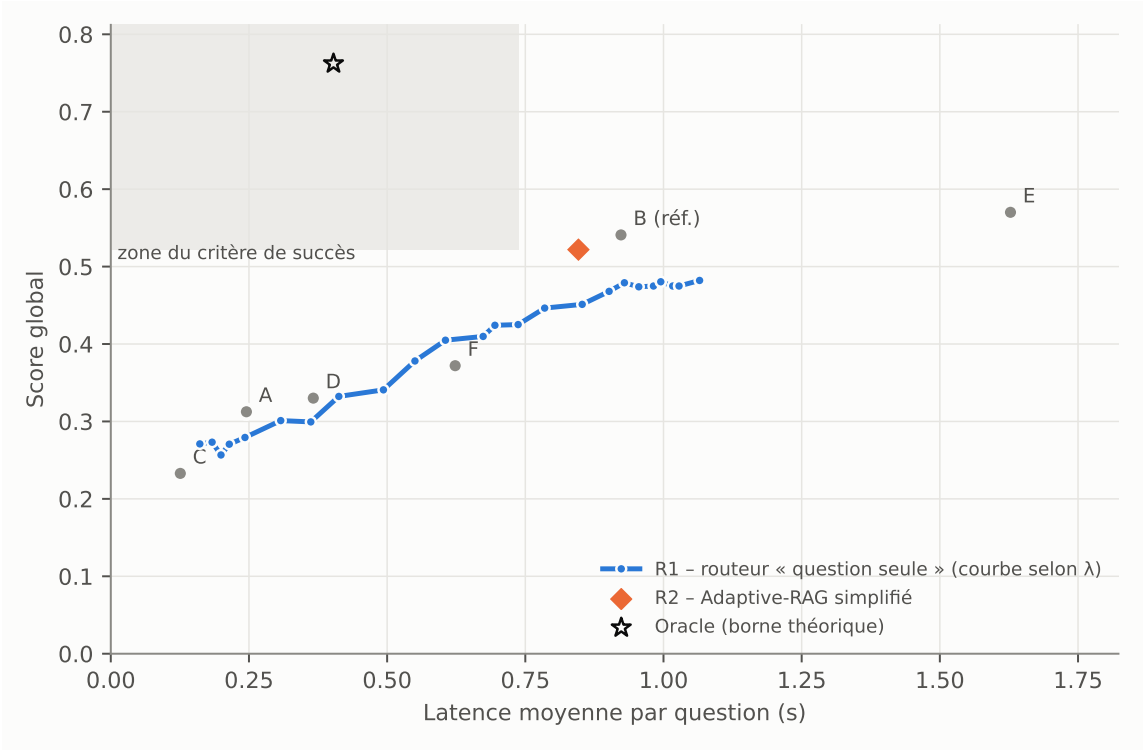


FIGURE 1 – Compromis qualité–coût sur le jeu de développement. Points gris : stratégies fixes. Courbe bleue : R1 pour 26 valeurs de λ. Losange orange : R2. Étoile : oracle. La zone grisée correspond au critère principal : au moins 20 % plus rapide que B, pour au plus 2 points de score en moins.

R1 ne fait pas mieux que toujours choisir B. Même au réglage qui privilégie la qualité ($\lambda = 0$), R1 n'atteint que 0,48, soit moins que B (0,54), pour une latence supérieure. Dès qu'on lui

impose d'être 20 % plus rapide, il perd 11,6 points. Sur ce benchmark, le texte de la question ne permet pas de prédire de façon fiable quelle stratégie réussira. Une explication plausible, qui reste à vérifier, est que la réussite dépend surtout de ce que contient le corpus et de ce que sait le modèle, deux informations que la question seule ne révèle pas.

R2 garde la qualité de B, mais gagne peu de temps. En choisissant entre 0, 3 et 6 passages, R2 obtient 0,522, à moins de 2 points de B (écart non significatif), pour 8 % de latence en moins. Il économise du temps en répondant sans recherche à 38 questions, dont il est d'ailleurs bon juge pour les questions non couvertes (0,73 contre 0,58 pour B). En revanche, son classifieur de complexité ne prédit la bonne étiquette que dans 42 % des cas, et il ne choisit jamais le petit modèle : son gain de coût est donc plafonné.

La marge reste très grande. L'oracle montre qu'en choisissant la bonne stratégie pour chaque question, on pourrait à la fois améliorer le score de 22 points et diviser la latence par plus de deux. Les deux routeurs n'en captent presque rien.

6 Ce que la méthode adaptative devra démontrer

Ces résultats fixent la barre de la Partie IV et en orientent la conception :

1. **Battre B sous la contrainte du critère principal** : au moins 20 % plus rapide que 0,92 s, soit moins de 0,74 s, pour au plus 2 points de score en moins, soit au moins 0,52 sur le jeu de développement.
2. **Battre R1 et R2** : un gain qui ne dépasserait pas ces routeurs ne justifierait pas des signaux plus coûteux.
3. **Utiliser d'autres signaux que la question** : la Partie III montre qu'ils sont nécessaires. Les candidats, peu coûteux, sont le score BM25 des passages récupérés (suffisance des preuves), l'incertitude du petit modèle sur sa réponse (cascade, comme AutoMix) et l'accord entre une réponse sans et avec recherche. Leur coût sera compté dans la latence.
4. **Décider l'abstention explicitement** : la couverture de B (0,62) s'accompagne d'un risque de 0,39 ; l'oracle obtient un risque de 0,19. Mieux décider quand s'abstenir est un levier de fiabilité autant que de coût.

7 Limites

— **Petite taille du jeu de développement** : 180 questions donnent des intervalles de confiance d'environ ±7 points sur le score global. Les écarts de quelques points entre routeurs ne sont pas significatifs.

— **Évaluation optimiste des routeurs** : le point de fonctionnement de R1 est choisi sur les mêmes questions (section 4).

— **Adaptive-RAG simplifié** : classifieur linéaire et recherche non itérative. Les conclusions portent sur cette version, pas sur l'implémentation originale.

— **Énergie** : elle n'a pas été remesurée avec la recherche BM25 ; les chiffres d'énergie de L2 portent sur la recherche dense du pilote. Elle sera mesurée lors de l'évaluation finale.

A Reproduire

```
HF_HUB_OFFLINE=1 python bench/compare_retrieval.py     # tableau 1
HF_HUB_OFFLINE=1 python bench/run_strategies.py dev    # stratégies A à F
python bench/routers.py dev                            # routeurs R1 et R2
python bench/plot_partie3.py                           # figure qualité-coût
```

Références

Dujian Ding, Ankur Mallick, Chi Wang, Robert Sim, Subhabrata Mukherjee, Victor Ruhle, Laks V. S. Lakshmanan, and Ahmed Hassan Awadallah. Hybrid LLM : Cost-Efficient and Quality-Aware Query Routing. In *International Conference on Learning Representations (ICLR)*, 2024. URL https://arxiv.org/abs/2404.14618.

Soyeong Jeong, Jinheon Baek, Sukmin Cho, Sung Ju Hwang, and Jong C. Park. Adaptive-RAG : Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity. In *Proceedings of NAACL-HLT 2024*, 2024. URL https://arxiv.org/abs/2403.14403.

Qiaomu Li, Qiuyuan Zhang, and Nong Ming. Beyond the Query : Do Retrieval Signals Improve Adaptive Multimodal RAG Routing ? arXiv preprint arXiv :2609.12437, 2026. URL https://arxiv.org/abs/2609.12437.