Livrable L5 – Évaluation finale

Allocation adaptative des ressources de calcul et de recherche documentaire
pour des systèmes LLM locaux, économes et fiables

Exécution unique sur le jeu de test, verdict sur les critères pré-enregistrés, ablations et énergie

Alae Lahbichi – Étudiant en 5e année IA/Data

a.lahbichi2004@gmail.com

Dépôt GitHub : AlaeLahbichi/Adaptive-Compute-and-RAG-for-Efficient-Reliable-Local-LLMs

18 octobre 2026

Résumé

La politique adaptative figée en Partie IV a été exécutée une seule fois sur les 450 questions du jeu de test, avec les six stratégies fixes, les routeurs de référence R1 et R2 et une mesure d'énergie. Sa **qualité est au niveau de la référence B** (score global 0,550 contre 0,537, soit +1,3 point ; intervalle à 95 % de la perte : [−4,1 ; +1,6] points, donc non-infériorité démontrée) et elle **bat les deux routeurs de référence** (R1 : 0,489 ; R2 : 0,517). En revanche, elle ne réduit la latence moyenne que de **10 %** (0,79 s contre 0,87 s), loin des 20 % exigés, et l'énergie par question de 9 %. **Le critère de succès principal n'est donc pas atteint.** La cause est identifiée : l'abstention précoce, réglée sur 180 questions, se déclenche sur 25 % des questions de développement mais seulement sur 15 % des questions de test. Le critère de robustesse échoue aussi (perte de 7,6 points sur les questions simples).

Table des matières

1 Rôle de cette partie 3

2 Déroulement 3

3 Verdict sur les critères pré-enregistrés 3

4 Résultats détaillés 4

5 Ablations 5

6 Énergie 6

7 Comparaison avec le jeu de développement 7

8 Discussion et limites 7

A Reproduire 8

1 Rôle de cette partie

Les Parties II à IV ont fixé le protocole (`protocole-v1.0`), construit les méthodes de référence et réglé la politique adaptative (`politique-v1.0`), le tout sur le jeu de développement. La Partie V applique *une seule fois* toutes les méthodes aux 450 questions du jeu de test, jamais utilisées jusque-là, et confronte les résultats aux critères de succès écrits avant les expériences (L2, section 8). C'est la seule mesure non biaisée de l'étude.

2 Déroulement

— **Méthodes exécutées** : les six stratégies fixes (A à F) et la politique adaptative, exécutée réellement de bout en bout. Les routeurs de référence R1 et R2, entraînés sur le jeu de développement avec les réglages de la Partie III, sont appliqués aux sorties des stratégies sur le test. L'oracle est calculé de la même manière.

— **Trois passes complètes**, conformément au protocole : la latence retenue pour chaque question est la médiane des trois passes ; la qualité provient de la première passe, la génération étant déterministe. Dans chaque passe, l'ordre des méthodes est tiré au hasard (graine fixe) pour répartir l'effet de l'échauffement de la machine.

— **Énergie** mesurée par `powermetrics` pendant toute l'évaluation (puissance CPU + GPU + ANE, toutes les 200 ms), après 20 s de mesure au repos. L'énergie par question inclut les 3 requêtes de chauffe de chaque méthode dans le dénominateur.

— **Aucun réglage** n'a été modifié après l'exécution sur le test.

Bilan de l'exécution. 9 450 sorties ont été produites (7 méthodes × 450 questions × 3 passes) en environ 2 h. Deux contrôles valident l'exécution :

— **Stabilité** : pour toutes les méthodes, les trois passes donnent exactement la même réponse sur 100 % des questions ; seule la latence varie.

— **Fidélité de la simulation** : rejouer la politique à partir des sorties des stratégies fixes (comme lors du réglage en Partie IV) reproduit son score sur 100 % des questions (0,550) et sa latence à 0,001 s près (0,786 s simulée contre 0,786 s mesurée). Le réglage par simulation de la Partie IV était donc exact.

3 Verdict sur les critères pré-enregistrés

Le tableau 1 reprend un à un les critères écrits dans le cahier expérimental (L2) avant toute expérience.

Critère pré-enregistré	Mesure sur le test	Atteint
Principal – latence moyenne réduite d'au moins 20 % par rapport à B	−10,1 % (0,786 contre 0,873 s)	✗
Principal – perte de score global ≤ 2 points	−1,3 point (gain)	✓
Non-infériorité : borne haute de l'IC à 95 % de la perte < 2 points	[−4,1 ; +1,6]	✓
Critère principal (les deux conditions)		✗
Risque (erreurs parmi les réponses données) inférieur à B	0,395 contre 0,421	✓
Meilleur score que R1 (routeur « question seule »)	0,550 contre 0,489	✓
Meilleur score que R2 (Adaptive-RAG simplifié)	0,550 contre 0,517	✓
Robustesse : aucune catégorie ne perd plus de 5 points	simple −7,6 ; complexe −3,3 ; non couverte +14,7	✗

TABLE 1 – Verdict sur les critères de succès pré-enregistrés (jeu de test, 450 questions). Les intervalles sont obtenus par bootstrap apparié (10 000 tirages).

Conclusion. L'hypothèse principale est **rejetée dans sa forme pré-enregistrée** : la politique conserve la qualité de B, avec moins d'erreurs, mais n'économise que la moitié de la latence visée. Le résultat positif est réel mais plus modeste : à qualité égale (non-infériorité démontrée), la politique est 10 % plus rapide et 9 % plus économe en énergie que B, et elle domine les deux routeurs de la littérature reproduits ici, qui sont à la fois moins bons et, pour R2, à peine plus rapides.

4 Résultats détaillés

Méthode	Score	IC 95 %	Écart à B	Latence	P95	Couv.	Risque
A – grand, sans RAG	0,310	[0,269 ; 0,351]	−22,7	0,27 s	0,52 s	0,45	0,76
B – grand, 3 passages (réf.)	**0,537**	[0,494 ; 0,581]	–	**0,87 s**	1,26 s	0,73	0,42
C – petit, sans RAG	0,223	[0,187 ; 0,261]	−31,4	0,13 s	0,25 s	0,51	0,93
D – petit, 3 passages	0,414	[0,372 ; 0,457]	−12,3	0,35 s	0,53 s	0,88	0,57
E – grand, 6 passages	0,567	[0,523 ; 0,610]	+3,0	1,57 s	2,23 s	0,75	0,40
F – petit, 6 passages	0,398	[0,357 ; 0,440]	−13,9	0,61 s	0,87 s	0,94	0,60
R1 – question seule	0,489	[0,445 ; 0,534]	−4,7	0,74 s	1,61 s	0,68	0,48
R2 – Adaptive-RAG simplifié	0,517	[0,473 ; 0,561]	−2,0	0,82 s	1,39 s	0,68	0,44
Politique adaptative	**0,550**	[0,505 ; 0,594]	**+1,3**	**0,79 s**	1,38 s	0,64	**0,40**
Oracle	*0,797*	[0,762 ; 0,831]	+26,0	*0,36 s*	1,09 s	0,64	0,18

TABLE 2 – Résultats sur le jeu de test (450 questions). Latence : moyenne par question de la médiane des trois passes. Couv. : part des questions auxquelles la méthode répond ; risque : part de réponses fausses parmi elles.

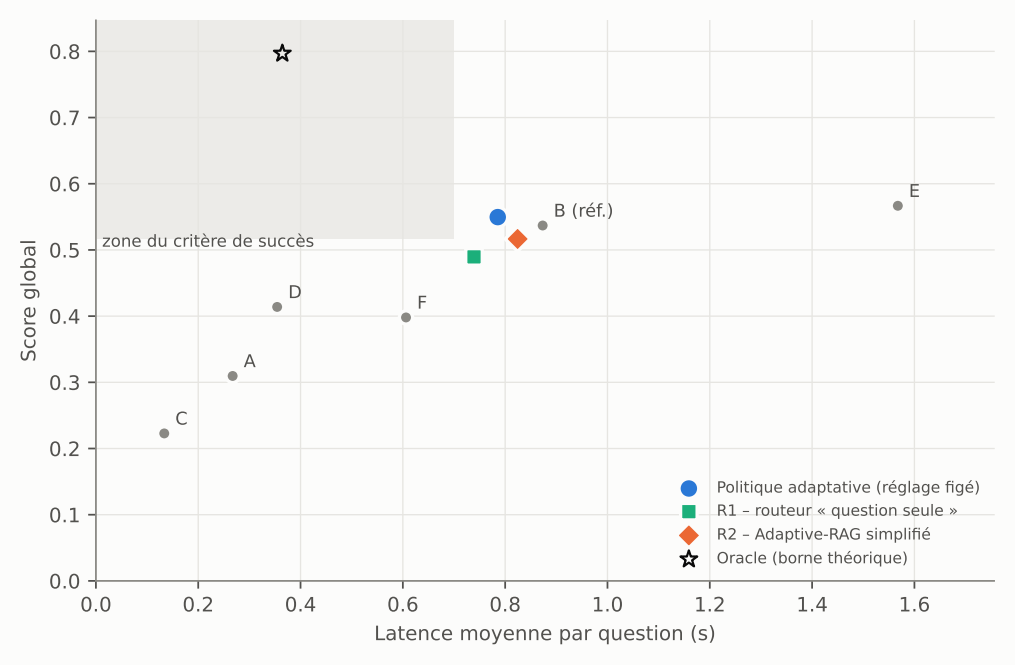


FIGURE 1 – Compromis qualité–latence sur le jeu de test. La zone grisée est celle du critère de succès (latence $\leq 0{,}8\times$B, perte ≤ 2 points). La politique adaptative (en bleu) est au-dessus de B mais à droite de la zone.

Par catégorie. Le tableau 3 montre que la politique échange de la qualité sur les questions qui ont une réponse contre de la fiabilité sur les questions sans réponse.

Méthode	Simple	Complexe	Non couverte
B – référence	0,737	0,468	0,407
E – grand, 6 passages	0,730	0,537	0,433
R1	0,562	0,453	0,453
R2	0,635	0,455	0,460
Politique adaptative	0,661 (−7,6)	0,435 (−3,3)	**0,553** (+14,7)
Oracle	0,842	0,682	0,867

TABLE 3 – Score par catégorie (150 questions chacune). Entre parenthèses : écart de la politique à B, en points.

Choix de la politique. Sur 450 questions : 66 abstentions précoces (15 %), 359 réponses du grand modèle avec 3 passages et 25 avec 6 passages ; parmi ces 384 réponses, 98 ont ensuite été remplacées par une abstention finale. L'abstention précoce touche surtout les questions non couvertes (36 sur 150), mais aussi 18 questions simples et 12 complexes, ce qui explique la perte sur ces catégories. Le grand modèle à 6 passages n'est choisi que pour 6 % des questions : la recherche adaptative joue un rôle mineur.

5 Ablations

Les variantes de la politique, réglées sur le jeu de développement en Partie IV, sont appliquées au test par simulation (dont la fidélité est vérifiée ci-dessus).

Variante	Score (test)	Latence (test)	Score (dev)	Latence (dev)
Politique complète	**0,550**	0,79 s	0,552	0,71 s
Sans cascade (identique : la cascade n'est pas retenue)	0,550	0,79 s	0,552	0,71 s
Sans recherche adaptative (toujours 3 passages)	0,547	0,74 s	0,548	0,68 s
Sans abstention finale	0,547	0,79 s	0,546	0,71 s
Sans abstention précoce (cascade petit → grand)	0,464	0,64 s	0,395	0,70 s
Sans aucune abstention	0,457	0,64 s	0,389	0,70 s

TABLE 4 – Ablations. Chaque variante a été réglée sur le développement sous la même contrainte de latence.

— Les conclusions de la Partie IV se confirment : **l'abstention précoce fondée sur la qualité des preuves est la composante essentielle** (−8,6 points sans elle).

— La recherche adaptative (3 ou 6 passages) et l'abstention finale n'apportent chacune que 0,3 point, dans le bruit statistique. Sur le test, *toujours* utiliser 3 passages serait même plus rapide (0,74 s, soit −15 % par rapport à B) pour un score équivalent.

— Aucune variante n'atteint à la fois −20 % de latence et une perte ≤ 2 points.

6 Énergie

L'énergie a été mesurée par `powermetrics` sur toute l'évaluation (30 630 relevés ; puissance au repos : 2,7 W). Le tableau 5 donne la moyenne des trois passes.

Méthode	Énergie / question	Écart à B	Puissance moyenne
C – petit, sans RAG	1,8 J	−90 %	16,4 W
A – grand, sans RAG	3,9 J	−80 %	17,0 W
D – petit, 3 passages	7,3 J	−62 %	23,2 W
F – petit, 6 passages	13,5 J	−30 %	24,9 W
Politique adaptative	**17,5 J**	**−9** %	24,8 W
B – grand, 3 passages (réf.)	19,3 J	–	24,7 W
E – grand, 6 passages	37,7 J	+95 %	26,4 W

TABLE 5 – Énergie (CPU + GPU + ANE) par question sur le jeu de test.

La puissance appelée varie peu (16 à 26 W) : l'énergie est presque proportionnelle à la durée de calcul, donc aux tokens traités. L'économie d'énergie de la politique (−9 %) suit sa réduction de latence (−10 %). Passer de 3 à 6 passages double l'énergie pour 3 points de score.

7 Comparaison avec le jeu de développement

Méthode	Développement (180) Score	Latence	Test (450) Score	Latence
B – référence	0,541	0,92 s	0,537	0,87 s
Politique (réglage figé, estimation optimiste)	0,552	0,71 s (−23 %)	0,550	0,79 s (−10 %)
Politique (validation croisée sur dev)	0,520	−22 %	–	–
R1	0,425	0,74 s	0,489	0,74 s
R2	0,522	0,85 s	0,517	0,82 s
Oracle	0,762	0,40 s	0,797	0,36 s
Abstentions précoces de la politique	45 / 180 (25 %)		66 / 450 (15 %)	

Table 6 – Développement et test.

— **La qualité s'est bien généralisée**, mieux même que ne le prévoyait la validation croisée (0,550 au lieu de 0,520) : la sélection du réglage n'a pas sur-ajusté le score.

— **Le gain de latence ne s'est pas généralisé.** Le seuil d'abstention précoce (preuve BM25 normalisée $< 0{,}265$) a été réglé sur 60 questions par catégorie : il coupait 25 % des questions de développement, mais la même valeur ne coupe que 15 % des questions de test (écart d'environ trois erreurs-types, attribuable à la variabilité d'échantillonnage d'un petit jeu de réglage). Moins d'abstentions précoces signifie plus d'appels au grand modèle, donc une latence plus proche de B. La validation croisée, faite sur le même petit échantillon, n'a pas pu révéler ce problème.

— Le compromis par catégorie garde le même sens (pertes sur les questions simples, gain sur les questions non couvertes) mais avec une ampleur réduite de moitié, cohérente avec la baisse du taux d'abstention précoce.

8 Discussion et limites

Ce que l'étude établit.

1. Sur machine locale, **la qualité des preuves récupérées est un signal de routage plus utile que la question elle-même** : la politique, fondée sur la preuve BM25 et la confiance du modèle, bat les deux routeurs fondés sur la question (R1, R2), à latence comparable.
2. L'**abstention** est le levier qui rend l'adaptation rentable : elle réduit le risque (0,40 contre 0,42) et la latence en même temps. Sans elle, toute tentative d'économie (petit modèle, cascade) coûte 8 à 15 points.
3. Le petit modèle (1,5 milliard de paramètres) n'a pas de place utile dans la politique : sur ce benchmark, ses erreurs ne sont pas assez bien signalées par sa confiance pour qu'une cascade soit rentable.
4. L'écart à l'oracle (26 points, −58 % de latence) reste considérable : le problème n'est pas l'absence de bons choix, mais la difficulté à les prédire.

Limites.

— **Taille du jeu de développement** : 180 questions ne suffisent pas pour régler des seuils absolus de manière stable ; c'est la cause directe de l'échec du critère de latence.

— **Benchmark construit** : questions issues de SQuAD 2.0 et HotpotQA, corpus fermé de 3 293 passages, en anglais ; les questions non couvertes sont des questions adverses de SQuAD 2.0. Les questions ambiguës prévues au protocole n'ont pas été annotées et sont absentes du test.

— **Métrique** : le F1 lexical pénalise les réponses correctes formulées différemment.

— **Matériel unique** (Apple M3 Pro, MLX, quantification 4 bits) ; les écarts de latence entre modèles peuvent différer sur GPU ou avec un autre moteur d'inférence.

— **Énergie** : `powermetrics` mesure la puce (CPU, GPU, ANE), pas la consommation murale ; les mesures sont comparatives.

Pistes (sans modifier ce verdict). Régler les seuils en quantiles de la distribution des preuves plutôt qu'en valeurs absolues ; agrandir le jeu de développement ; viser une contrainte de latence plus stricte au réglage (marge de sécurité) ; étudier des signaux de preuve plus riches que BM25 (écart entre premiers passages, accord entre passages). Ces pistes devront être testées sur un nouveau jeu de test : celui-ci est désormais consommé.

A Reproduire

```
git checkout politique-v1.0
SUDO_MDP=... HF_HUB_OFFLINE=1 python bench/run_final.py   # 3 passes, énergie
python bench/evaluate_final.py                            # analyse et verdict
python bench/plot_partie4.py test                         # figure
```