Router par la preuve et s'abstenir à temps : allocation adaptative du calcul et de la recherche documentaire pour des LLM locaux

Une évaluation pré-enregistrée de la qualité, de la latence et de l'énergie sur matériel local

Alae Lahbichi – Étudiant en 5e année IA/Data

a.lahbichi2004@gmail.com

Code et données : github.com/AlaeLahbichi/Adaptive-Compute-and-RAG-for-Efficient-Reliable-Local-LLMs

18 octobre 2026

Résumé

Un système de questions-réponses exécuté sur une machine personnelle doit décider, pour chaque question, quel modèle de langage utiliser, combien de documents récupérer, et s'il vaut mieux s'abstenir. Ces trois décisions sont presque toujours étudiées séparément, et leur coût exprimé en prix d'API plutôt qu'en latence ou en énergie mesurées. Nous proposons une politique adaptative simple qui les prend conjointement à partir de deux signaux peu coûteux : la *suffisance des preuves*, calculée à partir du score BM25 du meilleur passage, et la *confiance* du modèle, lue dans les probabilités des tokens générés. Nous l'évaluons sur un Apple M3 Pro avec deux modèles Qwen quantifiés en 4 bits (1,5 et 4 milliards de paramètres), sur un benchmark de 630 questions dérivé de SQuAD 2.0 et HotpotQA, avec des critères de succès fixés avant les expériences et un jeu de test utilisé une seule fois. Sur 450 questions de test, la politique atteint la qualité de la référence « grand modèle + RAG » (score 0,550 contre 0,537 ; non-infériorité démontrée), avec moins de réponses fausses (risque 0,40 contre 0,42), et dépasse deux routeurs de la littérature fondés sur la question seule (0,489 et 0,517). Elle ne réduit toutefois la latence que de 10 % et l'énergie de 9 %, au lieu des 20 % visés : **le critère principal n'est pas atteint**. L'analyse attribue cet échec au réglage d'un seuil d'abstention absolu sur un trop petit jeu de développement. Nous détaillons les points faibles de l'étude et un programme d'améliorations concret.

Mots-clés : LLM locaux, routage de modèles, RAG adaptatif, abstention, efficacité énergétique, évaluation pré-enregistrée.

Table des matières

1 Introduction **3**

2 Travaux connexes **3**

3 Méthode **4**
3.1 Signaux 4
3.2 Politique 4
3.3 Réglage 4

4 Protocole expérimental **4**

5 Résultats **5**
5.1 Résultats principaux 6
5.2 Verdict sur les critères pré-enregistrés 6
5.3 Ablations 7
5.4 Énergie 7
5.5 Du développement au test 7

6 Discussion **7**

7 Points faibles et améliorations **7**
7.1 Faiblesses de la méthode 7
7.2 Faiblesses du protocole 8

8 Conclusion **9**

1 Introduction

Les modèles de langage (LLM) de quelques milliards de paramètres, quantifiés, tournent désormais sur un ordinateur portable. Les exécuter localement protège les données et supprime la dépendance à un service distant, mais chaque requête a un coût direct : temps d'attente, mémoire, énergie. La recherche documentaire (RAG) améliore la factualité (Gao et al., 2023), mais elle allonge le prompt et donc la latence. Un grand modèle répond mieux qu'un petit, mais plus lentement. Et lorsque les documents ne contiennent pas la réponse, le meilleur choix est souvent de ne pas répondre (Wen et al., 2024).

Appliquer la configuration la plus coûteuse à toutes les questions gaspille des ressources sur les questions faciles ; appliquer la moins coûteuse dégrade la qualité sur les questions difficiles. D'où la question de recherche :

> *Comment allouer automatiquement, et de manière mesurable, les ressources de calcul et de recherche documentaire à chaque requête, afin de réduire le coût d'un système LLM local sans dégrader significativement la qualité, la factualité et la fiabilité des réponses ?*

Contributions.

1. Une **politique adaptative conjointe** (modèle × nombre de passages × abstention), fondée sur deux signaux quasi gratuits et interprétables : la suffisance des preuves BM25 et la confiance du modèle (section 3).
2. Un **protocole d'évaluation pré-enregistré** sur matériel local : critères de succès écrits avant les expériences, jeu de test utilisé une seule fois, latence mesurée sur trois passes, énergie mesurée par `powermetrics` (section 4).
3. Une **comparaison** avec six stratégies fixes, deux routeurs de référence inspirés de la littérature et un oracle (section 5).
4. Un **résultat négatif documenté** : la qualité est préservée mais le gain de latence visé n'est pas atteint ; nous en identifions la cause et proposons des améliorations (sections 7 et 8).

2 Travaux connexes

Routage et cascades de modèles. FrugalGPT (Chen et al., 2023) enchaîne des modèles de coût croissant et s'arrête dès qu'une réponse est jugée fiable ; AutoMix (Aggarwal et al., 2023) et Yue et al. (2023) escaladent selon l'auto-vérification ou la cohérence des réponses. Hybrid LLM (Ding et al., 2024) et RouteLLM (Ong et al., 2024) prédisent, *avant* la génération, si un petit modèle suffit. RouterBench (Hu et al., 2024) et la revue de Varangot-Reille et al. (2026) montrent que le coût y est presque toujours un prix d'API. Plus récemment, RACER (Hao et al., 2026) apporte des garanties conformes au routage.

RAG adaptatif. Mallen et al. (2023) montrent que la recherche est surtout utile pour les connaissances rares. Adaptive-RAG (Jeong et al., 2024) choisit entre aucune, une ou plusieurs étapes de recherche selon la complexité prédite de la question. FLARE (Jiang et al., 2023) et DRAGIN (Su et al., 2024) déclenchent la recherche pendant la génération ; Self-RAG (Asai et al., 2024) et CRAG (Yan et al., 2024) évaluent la pertinence des documents récupérés. Moskvoretskii et al. (2025) montrent que des signaux d'incertitude simples rivalisent avec des pipelines complexes. RAGRouter-Bench (Wang et al., 2026) et Self-Routing RAG (Wu et al., 2025) routent entre paradigmes de RAG.

Incertitude et abstention. Les probabilités internes des modèles sont informatives (Kadavath et al., 2022) ; l'entropie sémantique (Kuhn et al., 2023) et SelfCheckGPT (Manakul et al., 2023) exploitent la cohérence entre échantillons, au prix de plusieurs générations. Kamath et al. (2020) formalisent la réponse sélective et ses métriques de couverture et de risque, que nous reprenons.

Énergie. Samsi et al. (2023) et Luccioni et al. (2024) mesurent l'énergie de l'inférence sur GPU de centre de données ; les mesures sur matériel personnel restent rares.

Positionnement. Ces travaux traitent le plus souvent *une* des trois décisions, et mesurent le coût en dollars ou en appels. Nous les traitons conjointement, avec un coût mesuré localement (latence, tokens, énergie), et nous reprenons comme références deux routeurs fondés sur la question seule, dans l'esprit de RouteLLM et d'Adaptive-RAG. Li et al. (2026) observent que des signaux extraits après la recherche surpassent la seule requête pour le routage : nos résultats vont dans le même sens.

3 Méthode

3.1 Signaux

Suffisance des preuves. Pour une question q, la recherche BM25 ($k_1 = 1{,}5$, $b = 0{,}75$) renvoie le score S_1 du meilleur passage. On le normalise par le score maximal atteignable :

$$\text{preuve}(q) \;=\; \frac{S_1}{\sum_{t \in q} \text{idf}(t)\,(k_1 + 1)} \;\in\; [0, 1].$$

Ce signal est un sous-produit de la recherche (0,2 ms) : il ne coûte rien.

Confiance du modèle. Pendant le décodage glouton, on relève la probabilité de chaque token produit, et on en retient la moyenne géométrique ou le minimum. Le décodage n'est pas modifié.

3.2 Politique

Pour chaque question :

1. **Abstention précoce** : si $\text{preuve}(q) < \tau_0$, répondre « je ne sais pas » sans aucune génération.
2. **Cascade** (optionnelle) : le petit modèle répond avec 3 passages ; si sa confiance dépasse τ_p, sa réponse est retenue.
3. **Grand modèle** sinon, avec 6 passages si $\text{preuve}(q) < \tau_k$, 3 sinon.
4. **Abstention finale** si la confiance du grand modèle est inférieure à τ_a.

Le coût de chaque étape exécutée est compté dans la latence.

3.3 Réglage

Les sorties étant déterministes, la politique se simule exactement à partir des sorties de chaque étape, latences comprises. Nous parcourons 246 510 réglages sur le jeu de développement et retenons celui qui maximise le score global sous la contrainte d'une latence moyenne au plus égale à 78 % de celle de la référence (2 points de marge par rapport au critère de 80 %). Le réglage retenu *n'utilise pas* la cascade : $\tau_0 = 0{,}265$, $\tau_k = 0{,}286$, et abstention finale si la probabilité minimale d'un token est inférieure à $\tau_a = 0{,}40$. Il a été figé et publié avant toute exécution sur le test.

Dit simplement : *si les documents ne contiennent manifestement pas les mots de la question, s'abstenir sans rien générer ; sinon, interroger le grand modèle, avec plus de passages si la preuve est limite, et s'abstenir s'il hésite.*

4 Protocole expérimental

Benchmark. Un corpus de 3 293 passages et 630 questions en trois catégories équilibrées : *simples* (SQuAD 2.0, réponse dans un passage, Rajpurkar et al., 2018), *complexes* (HotpotQA en configuration *distractor*, deux passages à combiner, Yang et al., 2018) et *non couvertes* (questions sans

réponse de SQuAD 2.0, pour lesquelles le comportement attendu est l'abstention). Développement : 180 questions ; test : 450 questions, jamais utilisées avant l'évaluation finale.

Modèles et matériel. Qwen2.5-1.5B-Instruct (« petit ») et Qwen3-4B-Instruct-2507 (« grand »), quantifiés en 4 bits, exécutés avec MLX sur un Apple M3 Pro (18 Go). Décodage glouton, 32 tokens au plus, prompts identiques avec consigne d'abstention explicite. La recherche BM25 a été préférée à une recherche dense (MiniLM) : rappel@3 de 0,59 contre 0,41 sur les questions avec réponse, pour un temps de 0,2 ms contre 7 ms.

Méthodes comparées.

— Six stratégies fixes : A et C (grand / petit modèle sans RAG), **B** (grand modèle avec 3 passages, **référence**), D (petit, 3 passages), E et F (grand / petit, 6 passages).

— R1 : régression par stratégie sur des caractéristiques de la question, choix qui maximise le score prédit moins une pénalité de latence (esprit RouteLLM).

— R2 : classifieur de complexité de la question choisissant entre A, B et E (Adaptive-RAG simplifié).

— Un oracle qui choisit, pour chaque question, la stratégie fixe la meilleure puis la plus rapide.

Métriques. Score global par question : F1 lexical si une réponse est attendue ; 1 si la méthode s'abstient sur une question non couverte, 0 sinon. Une réponse est correcte si F1 $\geq 0{,}5$. *Couverture* : part des questions où la méthode répond ; *risque* : part de réponses fausses parmi elles (Kamath et al., 2020). Latence de bout en bout ; énergie de la puce (CPU + GPU + ANE) par `powermetrics`. Intervalles de confiance par bootstrap apparié (10 000 tirages).

Critères de succès pré-enregistrés. Par rapport à B : latence moyenne réduite d'au moins 20 % *et* perte de score global d'au plus 2 points. Critères secondaires : risque plus faible que B, meilleur score que R1 et R2, aucune catégorie ne perdant plus de 5 points.

Exécution finale. Trois passes complètes sur le test, ordre des méthodes tiré au hasard dans chaque passe ; latence = médiane des trois passes par question. La politique est exécutée réellement de bout en bout.

5 Résultats

Les réponses sont identiques dans les trois passes pour toutes les méthodes, et la politique exécutée reproduit exactement sa simulation (accord de 100 % sur le score, latence à 0,001 s près).

5.1 Résultats principaux

Méthode	Score	IC 95 %	Écart à B	Latence	P95	Couv.	Risque
A – grand, sans RAG	0,310	[0,269 ; 0,351]	−22,7	0,27 s	0,52 s	0,45	0,76
B – grand, 3 passages (réf.)	**0,537**	[0,494 ; 0,581]	–	**0,87 s**	1,26 s	0,73	0,42
C – petit, sans RAG	0,223	[0,187 ; 0,261]	−31,4	0,13 s	0,25 s	0,51	0,93
D – petit, 3 passages	0,414	[0,372 ; 0,457]	−12,3	0,35 s	0,53 s	0,88	0,57
E – grand, 6 passages	0,567	[0,523 ; 0,610]	+3,0	1,57 s	2,23 s	0,75	0,40
F – petit, 6 passages	0,398	[0,357 ; 0,440]	−13,9	0,61 s	0,87 s	0,94	0,60
R1 – question seule	0,489	[0,445 ; 0,534]	−4,7	0,74 s	1,61 s	0,68	0,48
R2 – Adaptive-RAG simplifié	0,517	[0,473 ; 0,561]	−2,0	0,82 s	1,39 s	0,68	0,44
Politique adaptative	**0,550**	[0,505 ; 0,594]	**+1,3**	**0,79 s**	1,38 s	0,64	**0,40**
Oracle	*0,797*	[0,762 ; 0,831]	+26,0	*0,36 s*	1,09 s	0,64	0,18

TABLE 1 – Résultats sur le jeu de test (450 questions).

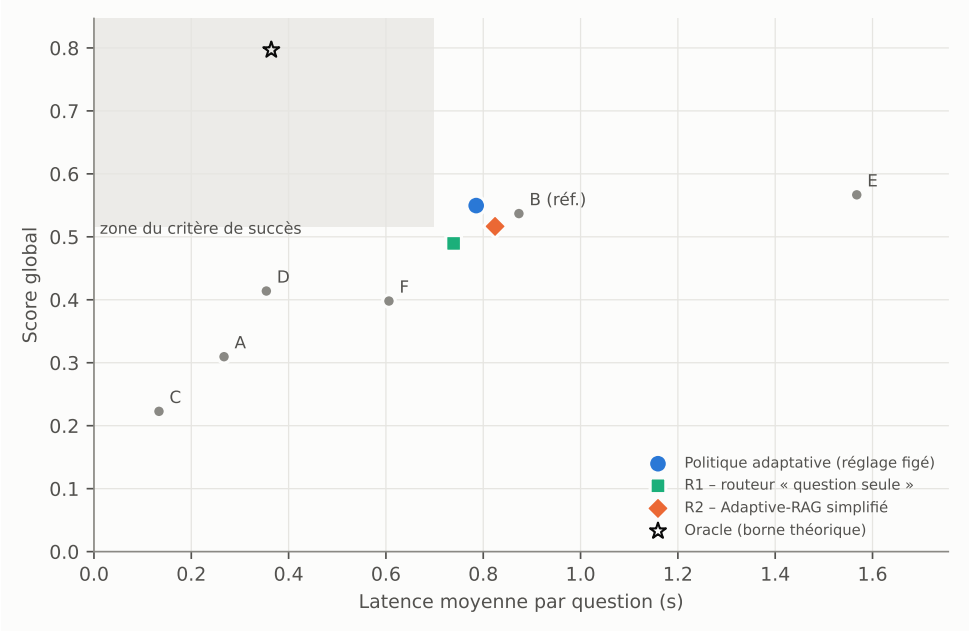


FIGURE 1 – Compromis qualité–latence sur le test. La zone grisée correspond au critère de succès.

5.2 Verdict sur les critères pré-enregistrés

Critère	Mesure	Atteint
Latence moyenne réduite d'au moins 20 %	−10,1 %	✗
Perte de score ≤ 2 points	−1,3 (gain) ; IC de la perte [−4,1 ; +1,6]	✓
Critère principal		✗
Risque inférieur à B	0,395 contre 0,421	✓
Meilleur que R1 et R2	0,550 contre 0,489 et 0,517	✓
Aucune catégorie ne perd plus de 5 points	simple −7,6 ; complexe −3,3 ; non couverte +14,7	✗

TABLE 2 – Verdict sur le jeu de test.

5.3 Ablations

Variante (réglée sur le développement)	Score	Latence
Politique complète	**0,550**	0,79 s
Sans recherche adaptative (toujours 3 passages)	0,547	0,74 s
Sans abstention finale	0,547	0,79 s
Sans abstention précoce (cascade petit → grand)	0,464	0,64 s
Sans aucune abstention	0,457	0,64 s

TABLE 3 – Ablations sur le test.

L'abstention précoce est la composante décisive (−8,6 points sans elle). La recherche adaptative et l'abstention finale n'apportent chacune que 0,3 point, dans le bruit statistique.

5.4 Énergie

L'énergie par question vaut 19,3 J pour B, 17,5 J pour la politique (−9 %), 37,7 J pour E et 1,8 J pour C. La puissance appelée varie peu (16 à 26 W) : l'énergie suit la durée de calcul, donc le nombre de tokens traités.

5.5 Du développement au test

Sur le développement, la politique obtenait 0,552 pour −23 % de latence ; sur le test, 0,550 pour −10 %. La qualité s'est généralisée, le gain de latence non. Le seuil d'abstention précoce coupait 25 % des questions de développement (45/180) mais seulement 15 % des questions de test (66/450). Moins d'abstentions précoces signifie plus d'appels au grand modèle, et une latence plus proche de B.

6 Discussion

1. **La preuve est un meilleur signal de routage que la question.** À latence comparable, la politique dépasse R1 de 6 points et R2 de 3 points. Regarder ce que la recherche a trouvé renseigne mieux que deviner la difficulté d'après la formulation.
2. **L'abstention rend l'adaptation rentable.** Ne pas générer sur une preuve faible économise du calcul et évite des erreurs : c'est la seule composante dont l'effet dépasse le bruit.
3. **Le petit modèle n'a pas trouvé sa place.** Sa confiance ne signale ses erreurs que modérément (AUC 0,74 sur le développement) et chaque escalade paie deux générations : la cascade n'a jamais été rentable sous la contrainte de latence.
4. **La marge reste considérable.** L'oracle atteint 0,797 en 0,36 s : les bons choix existent, c'est leur prédiction qui est difficile.

7 Points faibles et améliorations

Cette section recense les faiblesses de l'étude, de la plus importante à la moins importante, et pour chacune l'amélioration proposée. Le tableau 4 en fait la synthèse.

7.1 Faiblesses de la méthode

F1 – Seuils absolus réglés sur un petit échantillon. C'est la cause directe de l'échec du critère principal. Un seuil sur une valeur absolue de la preuve, réglé sur 60 questions par catégorie, ne déclenche pas la même proportion d'abstentions sur une autre distribution de questions. La validation croisée, faite sur le même petit échantillon, ne pouvait pas le révéler. *Améliorations :*

(i) exprimer les seuils comme des *quantiles* ou un *budget* (« s'abstenir sur les x % de questions aux preuves les plus faibles »), ce qui garantit le taux d'abstention, donc la latence ; (ii) calibrer les seuils avec une méthode conforme, qui donne des garanties de risque sans hypothèse sur la distribution (Hao et al., 2026) ; (iii) agrandir le jeu de réglage à au moins 500 questions ; (iv) régler avec une marge de sécurité dérivée de la variabilité observée par bootstrap, et non fixe.

F2 – Perte sur les questions simples (−7,6 points). L'abstention précoce touche aussi 18 questions simples et 12 complexes sur 150 : un score BM25 faible ne signifie pas toujours que la réponse est absente (reformulation, synonymes). La couverture baisse de 0,73 à 0,64. *Améliorations :* (i) remplacer la preuve lexicale par un juge de suffisance léger (re-classeur *cross-encoder* ou petit modèle d'inférence, dans l'esprit de CRAG (Yan et al., 2024) et Tiny-Critic RAG (Wu et al., 2026)) ; (ii) combiner preuve BM25 et preuve dense ; (iii) ajouter au réglage une contrainte par catégorie, de sorte qu'aucune ne perde plus de 5 points.

F3 – Signaux de confiance faibles. Aucun signal ne dépasse une AUC de 0,74, et l'abstention finale n'apporte que 0,3 point. La probabilité des tokens d'une réponse courte informe mal sur sa justesse. *Améliorations :* entropie sémantique (Kuhn et al., 2023) ou cohérence entre quelques échantillons, réservées aux cas limites pour en contenir le coût ; sonde entraînée sur les états internes du modèle (Kadavath et al., 2022).

F4 – Recherche adaptative quasi inutile. Choisir 6 passages au lieu de 3 ne concerne que 6 % des questions et n'apporte rien de mesurable ; toujours prendre 3 passages serait plus rapide (−15 %). Or les questions complexes ont un rappel@3 de seulement 0,37 : le problème n'est pas le *nombre* de passages mais la recherche elle-même. *Améliorations :* décomposition ou reformulation des questions multi-étapes, recherche itérative déclenchée par l'incertitude (Jiang et al., 2023; Su et al., 2024), compression du contexte pour réduire le coût des passages supplémentaires (Arefeen et al., 2024).

F5 – Le petit modèle est inutilisé. La politique finale n'utilise qu'un seul modèle : la dimension « choix du modèle » de la question de recherche n'est pas réellement exploitée. *Améliorations :* essayer un petit modèle plus performant ou spécialisé en extraction, ou l'employer pour un rôle moins exigeant (vérification, reformulation de requête) ; décodage spéculatif, où le petit modèle accélère le grand sans changer ses réponses.

F6 – Latence de queue dégradée. La latence P95 de la politique (1,38 s) dépasse celle de B (1,26 s) à cause des réponses à 6 passages. *Amélioration :* inclure le P95 dans l'objectif de réglage, ou plafonner le contexte.

F7 – Écart à l'oracle de 25 points. *Amélioration :* un routeur appris combinant caractéristiques de la question, preuve et confiance, entraîné sur un jeu bien plus grand que 180 questions.

7.2 Faiblesses du protocole

F8 – Benchmark construit et restreint. Questions en anglais tirées de SQuAD 2.0 et HotpotQA, corpus fermé de 3 293 passages ; les questions non couvertes sont des questions adverses de SQuAD 2.0, rédigées pour ressembler aux passages, ce qui n'est pas représentatif de l'usage réel ; la catégorie des questions ambiguës, prévue au protocole, n'a pas été annotée. *Améliorations :* ajouter MuSiQue (Trivedi et al., 2022) et CRAG (Yang et al., 2024), un corpus réel en français, et annoter au moins 50 questions ambiguës.

F9 – Métrique lexicale. Le F1 pénalise les réponses correctes formulées autrement (paraphrase, synonyme, date écrite autrement). *Amélioration :* juge sémantique (modèle d'inférence ou LLM juge), validé sur un échantillon annoté à la main.

F10 – Puissance statistique limitée. Avec 450 questions, l'intervalle de confiance du score est large d'environ ±4,4 points : un écart de 2 points, le seuil du critère, n'est pas détectable avec certitude. *Amélioration :* jeu de test d'au moins 1 500 questions.

F11 – Matériel et mesure uniques. Un seul appareil (M3 Pro, MLX, 4 bits) ; l'énergie est celle de la puce, pas la consommation murale. *Améliorations :* répliquer sur GPU NVIDIA et avec `llama.cpp`, mesurer au wattmètre, rapporter la mémoire.

F12 – Conception explorée sur le développement. Deux conceptions ont été essayées avant de figer la politique ; c'est documenté, mais cela augmente le risque de sur-ajustement au développement. *Amélioration :* pré-enregistrer aussi la *famille* de politiques, et pas seulement les critères. Toute amélioration devra être évaluée sur un **nouveau** jeu de test : celui-ci est désormais consommé.

	Faiblesse	Amélioration principale	Priorité
F1	Seuils absolus, petit jeu de réglage	Seuils en quantiles / budget, calibration conforme, ≥ 500 questions	Haute
F2	Perte sur les questions simples	Juge de suffisance léger, contrainte par catégorie	Haute
F10	Puissance statistique	Test $\geq 1\,500$ questions	Haute
F3	Signaux de confiance faibles	Cohérence entre échantillons sur les cas limites	Moyenne
F4	Recherche adaptative inutile	Décomposition des questions multi-étapes	Moyenne
F8	Benchmark restreint	MuSiQue, CRAG, corpus français, questions ambiguës	Moyenne
F9	Métrique lexicale	Juge sémantique validé	Moyenne
F5	Petit modèle inutilisé	Autre petit modèle, décodage spéculatif	Moyenne
F6	Latence P95	P95 dans l'objectif de réglage	Basse
F7	Écart à l'oracle	Routeur appris multi-signaux	Basse
F11	Matériel unique	Réplication GPU, wattmètre	Basse
F12	Exploration sur le développement	Pré-enregistrer la famille de politiques	Basse

TABLE 4 – Synthèse des points faibles et des améliorations.

8 Conclusion

Nous avons évalué, sur une machine personnelle et selon des critères fixés à l'avance, une politique qui décide conjointement du modèle, du nombre de passages et de l'abstention. Elle préserve la qualité de la configuration de référence, fait moins d'erreurs et dépasse deux routeurs fondés sur la question seule ; mais elle ne réduit la latence que de 10 % et l'énergie de 9 %, au lieu des 20 % visés. L'hypothèse principale est donc rejetée dans sa forme pré-enregistrée.

Deux enseignements dépassent ce résultat : sur machine locale, *la qualité des preuves récupérées est un signal de routage plus utile que la question elle-même*, et *savoir s'abstenir est ce qui permet d'économiser sans dégrader la fiabilité*. La prochaine étape est de rendre ce levier stable : exprimer l'abstention comme un budget calibré plutôt qu'un seuil absolu, mieux juger la suffisance des preuves, et valider le tout sur un jeu de test plus grand et neuf.

Reproductibilité. Code, benchmark, configurations figées (étiquettes `protocole-v1.0` et `politique-v1.0`), sorties brutes des trois passes et mesures d'énergie sont publiés dans le dépôt indiqué en première

page.

Références

Pranjal Aggarwal, Aman Madaan, Ankit Anand, Srividya Pranavi Potharaju, Swaroop Mishra, Pei Zhou, Aditya Gupta, Dheeraj Rajagopal, Karthik Kappaganthu, Yiming Yang, Shyam Upadhyay, Manaal Faruqui, and Mausam. AutoMix : Automatically Mixing Language Models. arXiv preprint arXiv :2310.12963, 2023. URL https://arxiv.org/abs/2310.12963.

Md Adnan Arefeen, Biplob Debnath, and Srimat Chakradhar. LeanContext : Cost-efficient domain-specific question answering using LLMs. *Natural Language Processing Journal*, 2024. doi : 10.1016/j.nlp.2024.100065.

Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. Self-RAG : Learning to Retrieve, Generate, and Critique through Self-Reflection. In *International Conference on Learning Representations (ICLR)*, 2024. URL https://arxiv.org/abs/2310.11511.

Lingjiao Chen, Matei Zaharia, and James Zou. FrugalGPT : How to Use Large Language Models While Reducing Cost and Improving Performance. arXiv preprint arXiv :2305.05176, 2023. URL https://arxiv.org/abs/2305.05176.

Dujian Ding, Ankur Mallick, Chi Wang, Robert Sim, Subhabrata Mukherjee, Victor Ruhle, Laks V. S. Lakshmanan, and Ahmed Hassan Awadallah. Hybrid LLM : Cost-Efficient and Quality-Aware Query Routing. In *International Conference on Learning Representations (ICLR)*, 2024. URL https://arxiv.org/abs/2404.14618.

Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, and Haofen Wang. Retrieval-Augmented Generation for Large Language Models : A Survey. arXiv preprint arXiv :2312.10997, 2023. URL https://arxiv.org/abs/2312.10997.

Sai Hao, Hao Zeng, Hongxin Wei, and Bingyi Jing. RACER : Risk-Aware Calibrated Efficient Routing for Large Language Models. arXiv preprint arXiv :2603.06616, 2026. URL https://arxiv.org/abs/2603.06616.

Qitian Jason Hu, Jacob Bieker, Xiuyu Li, Nan Jiang, Benjamin Keigwin, Gaurav Ranganath, Kurt Keutzer, and Shriyash Kaustubh Upadhyay. RouterBench : A Benchmark for Multi-LLM Routing System. arXiv preprint arXiv :2403.12031, 2024. URL https://arxiv.org/abs/2403.12031.

Soyeong Jeong, Jinheon Baek, Sukmin Cho, Sung Ju Hwang, and Jong C. Park. Adaptive-RAG : Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity. In *Proceedings of NAACL-HLT 2024*, 2024. URL https://arxiv.org/abs/2403.14403.

Zhengbao Jiang, Frank F. Xu, Luyu Gao, Zhiqing Sun, Qian Liu, Jane Dwivedi-Yu, Yiming Yang, Jamie Callan, and Graham Neubig. Active Retrieval Augmented Generation. In *Proceedings of EMNLP 2023*, 2023. URL https://arxiv.org/abs/2305.06983.

Saurav Kadavath, Tom Conerly, Amanda Askell, Tom Henighan, Dawn Drain, Ethan Perez, Nicholas Schiefer, Zac Hatfield-Dodds, Nova DasSarma, Eli Tran-Johnson, Scott Johnston, Sheer El-Showk, Andy Jones, Nelson Elhage, Tristan Hume, Anna Chen, Yuntao Bai, Sam Bowman, Stanislav Fort, Deep Ganguli, Danny Hernandez, Josh Jacobson, Jackson Kernion, Shauna Kravec, Liane Lovitt, Kamal Ndousse, Catherine Olsson, Sam Ringer, Dario Amodei, Tom Brown, Jack Clark, Nicholas Joseph, Ben Mann, Sam McCandlish, Chris Olah, and Jared Kaplan. Language Models (Mostly) Know What They Know. arXiv preprint arXiv :2207.05221, 2022. URL https://arxiv.org/abs/2207.05221.

Amita Kamath, Robin Jia, and Percy Liang. Selective Question Answering under Domain Shift. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020. URL https://arxiv.org/abs/2006.09462.

Lorenz Kuhn, Yarin Gal, and Sebastian Farquhar. Semantic Uncertainty : Linguistic Invariances for Uncertainty Estimation in Natural Language Generation. In *International Conference on Learning Representations (ICLR)*, 2023. URL https://arxiv.org/abs/2302.09664.

Qiaomu Li, Qiuyuan Zhang, and Nong Ming. Beyond the Query : Do Retrieval Signals Improve Adaptive Multimodal RAG Routing ? arXiv preprint arXiv :2609.12437, 2026. URL https://arxiv.org/abs/2609.12437.

Alexandra Sasha Luccioni, Yacine Jernite, and Emma Strubell. Power Hungry Processing : Watts Driving the Cost of AI Deployment ? In *ACM Conference on Fairness, Accountability, and Transparency (FAccT)*, 2024. URL https://arxiv.org/abs/2311.16863.

Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Daniel Khashabi, and Hannaneh Hajishirzi. When Not to Trust Language Models : Investigating Effectiveness of Parametric and Non-Parametric Memories. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*, 2023. URL https://arxiv.org/abs/2212.10511.

Potsawee Manakul, Adian Liusie, and Mark J. F. Gales. SelfCheckGPT : Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models. In *Proceedings of EMNLP 2023*, 2023. URL https://arxiv.org/abs/2303.08896.

Viktor Moskvoretskii, Maria Lysyuk, Mikhail Salnikov, Nikolay Ivanov, Sergey Pletenev, Daria Galimzianova, Nikita Krayko, Vasily Konovalov, Irina Nikishina, and Alexander Panchenko. Adaptive Retrieval Without Self-Knowledge ? Bringing Uncertainty Back Home. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2025. URL https://arxiv.org/abs/2501.12835.

Isaac Ong, Amjad Almahairi, Vincent Wu, Wei-Lin Chiang, Tianhao Wu, Joseph E. Gonzalez, M Waleed Kadous, and Ion Stoica. RouteLLM : Learning to Route LLMs with Preference Data. arXiv preprint arXiv :2406.18665, 2024. URL https://arxiv.org/abs/2406.18665.

Pranav Rajpurkar, Robin Jia, and Percy Liang. Know What You Don't Know : Unanswerable Questions for SQuAD. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2018. URL https://arxiv.org/abs/1806.03822.

Siddharth Samsi, Dan Zhao, Joseph McDonald, Baolin Li, Adam Michaleas, Michael Jones, William Bergeron, Jeremy Kepner, Devesh Tiwari, and Vijay Gadepally. From Words to Watts : Benchmarking the Energy Costs of Large Language Model Inference. arXiv preprint arXiv :2310.03003, 2023. URL https://arxiv.org/abs/2310.03003.

Weihang Su, Yichen Tang, Qingyao Ai, Zhijing Wu, and Yiqun Liu. DRAGIN : Dynamic Retrieval Augmented Generation based on the Information Needs of Large Language Models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024. URL https://arxiv.org/abs/2403.10081.

Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot, and Ashish Sabharwal. MuSiQue : Multihop Questions via Single-hop Question Composition. *Transactions of the Association for Computational Linguistics*, 2022. URL https://arxiv.org/abs/2108.00573.

Clovis Varangot-Reille, Christophe Bouvard, Antoine Gourru, Mathieu Ciancone, Marion Schaeffer, and François Jacquenet. Doing More with Less : A Survey on Routing Strategies for Resource Optimisation in Large Language Model-Based Systems. *Journal of Artificial Intelligence Research*, 2026. URL https://arxiv.org/abs/2502.00409.

Ziqi Wang, Xi Zhu, Shuhang Lin, Haochen Xue, Minghao Guo, and Yongfeng Zhang. RAGRouter-Bench : A Dataset and Benchmark for Adaptive RAG Routing. arXiv preprint arXiv :2602.00296, 2026. URL https://arxiv.org/abs/2602.00296.

Bingbing Wen, Jihan Yao, Shangbin Feng, Chenjun Xu, Yulia Tsvetkov, Bill Howe, and Lucy Lu Wang. Know Your Limits : A Survey of Abstention in Large Language Models. arXiv preprint arXiv :2407.18418, 2024. URL https://arxiv.org/abs/2407.18418.

Di Wu, Jia-Chen Gu, Kai-Wei Chang, and Nanyun Peng. Self-Routing RAG : Binding Selective Retrieval with Knowledge Verbalization. arXiv preprint arXiv :2504.01018, 2025. URL https://arxiv.org/abs/2504.01018.

Yichao Wu, Penghao Liang, Yafei Xiang, Mengwei Yuan, Jianan Liu, Jing Yang, Xianyou Li, and Weiran Yan. Tiny-Critic RAG : Empowering Agentic Fallback with Parameter-Efficient Small Language Models. arXiv preprint arXiv :2603.00846, 2026. URL https://arxiv.org/abs/2603.00846.

Shi-Qi Yan, Jia-Chen Gu, Yun Zhu, and Zhen-Hua Ling. Corrective Retrieval Augmented Generation. arXiv preprint arXiv :2401.15884, 2024. URL https://arxiv.org/abs/2401.15884.

Xiao Yang, Kai Sun, Hao Xin, Yushi Sun, Nikita Bhalla, Xiangsen Chen, Sajal Choudhary, Rongze Daniel Gui, Ziran Will Jiang, Ziyu Jiang, Lingkun Kong, Brian Moran, Jiaqi Wang, Yifan Ethan Xu, An Yan, Chenyu Yang, Eting Yuan, Hanwen Zha, Nan Tang, Lei Chen, Nicolas Scheffer, Yue Liu, Nirav Shah, Rakesh Wanga, Anuj Kumar, Wen tau Yih, and Xin Luna Dong. CRAG – Comprehensive RAG Benchmark. In *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2024. URL https://arxiv.org/abs/2406.04744.

Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William W. Cohen, Ruslan Salakhutdinov, and Christopher D. Manning. HotpotQA : A Dataset for Diverse, Explainable Multi-hop Question Answering. In *Proceedings of EMNLP 2018*, 2018. URL https://arxiv.org/abs/1809.09600.

Murong Yue, Jie Zhao, Min Zhang, Liang Du, and Ziyu Yao. Large Language Model Cascades with Mixture of Thoughts Representations for Cost-efficient Reasoning. arXiv preprint arXiv :2310.03094, 2023. URL https://arxiv.org/abs/2310.03094.